

Proyecto de Análisis Multivariante

Universidad Politécnica de Cataluña
Facultad de Matemáticas y Estadística

Diego Carrasco Parodi
Ferran Armengol Ayats
Gonzalo Jaén Sanz
Jovan Pomar Konstantinović

Juan Ignacio Sampere Bellver
Lília Molina Rodriguez
Max Ranz De La Iglesia
Pau Nerín Figuerola
Salomón Sabal Arriagada

21 de mayo de 2025

Agradecimientos

Datos

La base de datos escogida para este proyecto ha sido encontrada en la página web de Kaggle bajo el siguiente enlace: *Student Performance Factors*.

Base de datos original

El conjunto de datos *Student Performance Factors**recopila información sobre los elementos que pueden influir en el rendimiento académico de los estudiantes. Con un total de 6607 observaciones (alumnos), incluye variables que pueden afectar los resultados escolares. Véamos a continuación un resumen de las 20 variables presentes (13 categóricas y 7 numéricas discretas),

Nombre de la Variable	Tipo	Unidades	Missings
Horas estudiadas	Numérica	Horas por semana	0
Asistencia	Numérica	Porcentaje	0
Involucramiento Parental	Categórica	Bajo/Mediano/Alto	0
Acceso a Recursos	Categórica	Bajo/Mediano/Alto	0
Actividades Extraescolares	Categórica	Sí/No	0
Horas de Sueño	Numérica	Horas por día	0
Calificaciones Anteriores	Numérica	Porcentaje	0
Nivel de Motivación	Categórica	Bajo/Mediano/Alto	0
Acceso a Internet	Categórica	Sí/No	0
Sesiones de Tutoría	Numérica	Cantidad por mes	0
Ingreso Familiar	Categórica	Bajo/Mediano/Alto	0
Calidad del Profesorado	Categórica	Bajo/Mediano/Alto	78 (1.2 %) [†]
Tipo de Escuela	Categórica	Pública/Privada	0
Influencia de Pares	Categórica	Positiva/Neutra/Negativa	0
Actividad Física	Numérica	Horas por semana	0
Discapacidades de Aprendizaje	Categórica	Sí/No	0
Nivel de Educación Parental	Categórica	Bachiller/Grado/Posgrado	90 (1.4 %)
Distancia del Hogar	Categórica	Cercana/Moderada/Lejana	67 (1.0 %)
Género	Categórica	Masculino/Femenino	0
Calificación del Examen	Numérica	Porcentaje	0

Observamos que las variables categóricas son de dos o tres categorías. Luego, las variables Calidad del Profesorado, Nivel de Educación Parental y Distancia del Hogar presentan *missings*, entonces un alumno puede tener como mucho tres variables vacías. Hay un total de 235 *missings* que representa un $100 \frac{235}{n_{rows} \times n_{cols}} = 100 \frac{235}{6607 \times 20} \approx 0,18\%$. Véase en la Figura 1 el *barplot* correspondiente,

*Cabe remarcar que estos datos no son reales sino simulados, no provienen de ninguna entidad educativa.

[†]Los porcentajes no nulos de *missings* en función del total de casillas son respectivamente: 0.06 %, 0.07 % y 0.05 %.




Figura 1: Cantidad de valores faltantes por variable

Variable textual generada

Uno de los requisitos de la base de datos es la presencia de una variable textual, y nosotros no la tenemos. Así pues hemos decidido generarla de la siguiente manera. Creamos una función que, según la nota (variable Calificación del Examen), selecciona un comentario motivador: si es alta, felicitamos; si es media, animamos a mejorar; y si es baja, motivamos a esforzarse más. La nueva variable textual, Comentario del Profesor, tiene tres posibilidades que se asignan aleatoriamente para cada intervalo de notas, es decir,

Calificación del Examen	Comentario del Profesor
Nota baja: [0,50)	"You need to put in more effort to improve your scores." "Consider seeking extra help to better understand the topics." "Don't give up! Hard work will pay off."
Nota media: [50,75)	"Good job, but there's room for improvement!" "You're doing well, try to stay consistent." "Keep pushing yourself, you have potential!"
Nota alta: [75,100]	"Excellent performance! Keep up the great work!" "Outstanding effort, very proud of your progress!" "You demonstrate strong understanding of the concepts."

Para mayor comprensión, en todas las entregas se adjuntará un archivo *html* con el código usado en cada apartado.

Índice

1. Plan de Trabajo	7
1.1. Descomposición de tareas y diagrama de Gantt	7
1.2. Distribución de tareas entre los miembros del grupo y el Plan de Riesgos	9
2. Estructura de los datos y descriptiva	11
2.1. Motivación del trabajo	11
2.2. Descripción formal de la estructura de los datos	11
3. Descriptiva Univariante	14
3.1. Análisis descriptivo univariante inicial	14
3.1.1. Variables numéricas #	14
3.1.2. Variables categóricas #	15
3.2. Preprocesamiento de datos #	17
3.2.1. Tratamiento de <i>missings</i>	17
3.2.2. Tratamiento de <i>outliers</i>	19
3.3. Análisis univariante después del <i>preprocessing</i> #	23
4. Descriptiva Bivariante	24
4.1. Análisis descriptivo bivariante inicial	24
4.1.1. Numéricas vs Numéricas #	24
4.1.2. Categóricas vs Categóricas #	25
4.1.3. Numéricas vs Categóricas #	28
4.2. Análisis descriptivo bivariante de los datos preprocesados	33
4.2.1. Numéricas vs Numéricas	33
4.2.2. Categóricas vs Categóricas #	33
4.2.3. Numéricas vs Categóricas #	36
5. Clustering	42
5.1. Clustering particionales	42
5.1.1. Selección del <i>k</i> -óptimo #	42
5.1.2. Selección de diferentes métodos particionales #	45
5.2. Clustering jerárquicos #	48
6. Profiling	52
6.1. Clusters del k-means y PAM #	52
6.2. Clusters del jerárquico #	56
6.3. Comparación de resultados	59
7. ACP de las variables numéricas #	61
8. ACM de las variables cualitativas #	65
9. Análisis factorial de datos mixtos (FAMD) #	74

10.Clustering jerárquico sobre componentes factoriales	76
10.1. Clustering particional #	77
10.1.1. Selección del k -óptimo	77
10.1.2. Aplicación de diferentes métodos particionales	78
10.2. Profiling particional #	80
11.Análisis Discriminante #	83
11.1. Variables originales e índice del clustering jerárquico	83
11.2. Variables del PCA y del ACM e índice del clustering	84
11.3. Variables originales y Exam.Score discretizada	85
12.Análisis textual #	89
12.1. Preprocessing	89
12.2. Análisis sentimental	92
12.3. Topic modelling	96
13.Análisis comparativo	99
13.1. ACP	99
13.2. ACM	99
13.3. FAMD	99
13.4. Comparación de métodos	100
14.Conclusiones generales	102
15.Plan de trabajo Real	103

1. Plan de Trabajo

1.1. Descomposición de tareas y diagrama de Gantt

Nuestro grupo se organizará de la siguiente manera. Somos un total de nueve miembros de los cuáles hemos formado tres subgrupos de tres personas. El primer subgrupo compuesto por Diego, Lília y Pau; el segundo por Ferran, Max y Salomón; y el tercero por Gonzalo, Jovan y Juan Ignacio. Se asignará una tarea a cada subgrupo y cuando esté finalizada será compartida al grupo. Para cada tarea deberá contener dos partes: un *script* comentado en Rmarkdown que se enviará al grupo de *Whatsapp*, y un análisis riguroso con sus figuras pertinentes que deberá ser colgado al *Google Drive* compartido. Cuando todas las tareas se hallan acabado y revisado por varios miembros se procederá a editar un archivo *pdf* a latex y otros archivos *Rmarkdown* recopilando respectivamente el contenido del *Google Drive* y de todos los *scripts*. Estos dos últimos documentos son los que se entregarán al profesorado. En caso de que hayan varios *scripts* se adjuntarán unos hipervínculos (#) en este *pdf* para poder acceder al código de cualquier apartado rápidamente y proporcionar una lectura más cómoda e informativa.

Luego, una vez finalizado el análisis, para las entregas D3 y D4, se prepararán presentaciones con *Google Slides* resumiendo el trabajo. Véase a continuación en las Figuras 2 y 3 la descomposición en tareas de las entrega D3 y D4 y sus diagramas de Gantt.

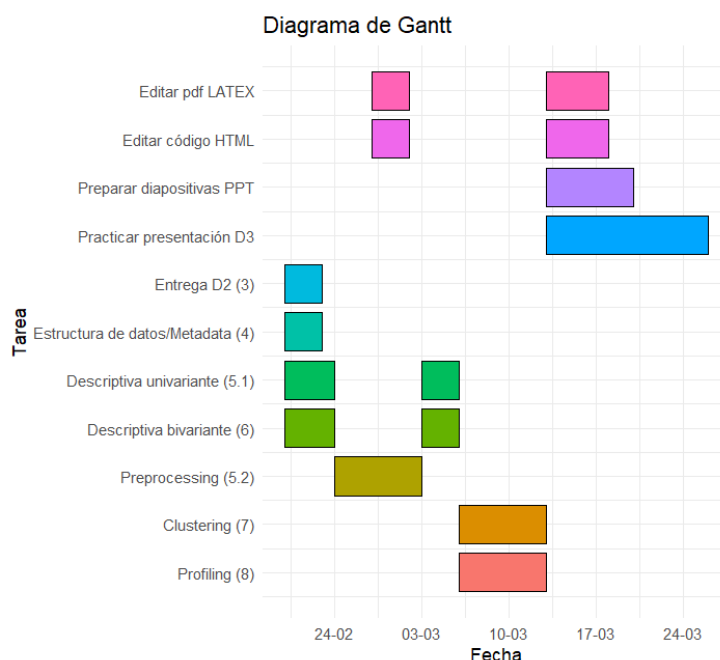


Figura 2: Diagrama de Gantt D3 (los números presentes en ciertas tareas corresponden con su apartado en el documento de *Instrucció del projecte* del Campus Virtual)




Figura 3: Diagrama de Gantt D4

1.2. Distribución de tareas entre los miembros del grupo y el Plan de Riesgos

En la siguiente Figura 4 observamos la distribución equitativa de tareas para ambas entregas D3 y D4.

Participant [†]	Diego	Ferran	Gonzalo	Jovan	Juan_Ignacio	Lilia	Max	Pau	Salomón
Editar pdf LATEX			x	X					
Editar código HTML	x							X	
Preparar diapositivas PPT				X	x	x			
Practicar presentación D3	x	x	x	x	x	x	x	x	x
Entrega D2 (3)				X					
Estructura de datos/Metadata (4)		X					x		x
Descriptiva univariante (5.1)			X		x				
Descriptiva bivariante (6)	x					x		X	
Preprocessing (5.2)		x					x		x
Clustering (7)		X1	x2	X2	x2		x1		x1
Profiling (8)	x					x		X	
ACP (9)			X	X	X				
ACM (10)		X					x		x
FAMD (11)	x					x		X	
Clustering FAMD (12)	x					x		X	
Análisis discriminante (13)			X	X	X				
Análisis Textual (14)		X					x		x
Análisis Comparativo, Conclusiones Generales (15,16)			X	X	X				
Plan de Trabajo y repartición real (17)				X					

[†] X: Líder de la tarea; x: Integrante de la tarea; Número: Apartado de la tarea

Figura 4: Distribución de tareas

Esta distribución no es definitiva y podrá cambiar a lo largo del análisis debido a nuestra ignorancia sobre varios métodos y sus dificultades de implementación.

Finalmente, el último requisito restante concerniente a la organización es el plan de riesgos que hemos elaborado en el Cuadro 2. Este también está sujeto a modificaciones futuras debido a nuestra inexperiencia al llevar a cabo un trabajo tan exhaustivo en cuanto a tiempo y personal.

Categoría	Riesgos Identificados	Probabilidad/Impacto	Estrategias de Mitigación y Contin- gencia
Gestión y Coordi- nación	Falta de comunicación interna Roles poco claros Conflictos interpersonales	Alta / Alto	Reuniones semanales Definición clara de roles Uso de herramientas colaborati- vas (Whatsapp y GoogleDrive)
Tiempo y Crono- grama	Retrasos en entregas Sobreestimación de tiempos Imprevistos personales	Alta / Alto	Revisiones periódicas y plan de contin- gencia
Técnico y de Datos	Calidad o disponibilidad de da- tos Errores en el análisis	Media / Alto	Realizar backups regulares Verificar y validar la información Acceso a soporte técnico (profeso- res/experto)
Presentaciones	Nervios o falta de preparación Retroalimentación insuficiente	Media / Alto	Ensayos y sesiones de retroali- mentación Preparación de materiales de apo- yo (powerpoint y resúmenes)

Cuadro 2: Tabla de riesgos

2. Estructura de los datos y descriptiva

2.1. Motivación del trabajo

La motivación de este estudio radica en la identificación de los factores más relevantes que influyen en el rendimiento académico de los estudiantes. A través del análisis de datos, buscamos detectar patrones y relaciones que permitan desarrollar estrategias efectivas para mejorar el aprendizaje y proporcionar herramientas de apoyo educativo. Con ello, pretendemos contribuir a la optimización de los métodos de enseñanza y a la toma de decisiones basada en evidencia dentro del ámbito educativo.

2.2. Descripción formal de la estructura de los datos

El conjunto de datos analizado, titulado *Student Performance Factors*, está compuesto por 6607 observaciones y 20 variables. Estas variables abarcan aspectos clave del rendimiento académico de los estudiantes, incluyendo factores personales, familiares, escolares y socioeconómicos.

Estructura del dataset

- Número total de observaciones (filas): 6607
- Número total de variables (columnas): 20
- Tipos de variables:
 - 7 numéricas (discretas) relacionadas con horas de estudio, asistencia, desempeño en exámenes, etc.
 - 13 categóricas de dos o tres niveles que incluyen factores como el acceso a recursos, la calidad docente y el tipo de escuela.

Ámbito del estudio El estudio se centra en la relación entre múltiples factores y el rendimiento académico, medido a través de la variable *Exam_Score* (puntaje en el examen final). Se analizan características tanto individuales como contextuales para comprender mejor su impacto en el aprendizaje.

Selección y filtrado No se han aplicado filtros ni eliminaciones, manteniendo la integridad del dataset original.

Fuente de datos

- Origen: Kaggle (Dataset: Student Performance Factors)
- Preprocesamiento previo: El dataset ha sido preparado sin valores perdidos en la mayoría de las variables, y se ha generado una nueva variable textual denominada *Comentario del Profesor*, asignando mensajes motivacionales en función del desempeño en el examen final.

Metadata

Variable	Descripción	Tipo	Valores posibles
Hours Studied	Número de horas dedicadas al estudio por semana.	Numérica (discreta)	$[0, \infty)$
Attendance	Porcentaje de asistencia a clases.	Numérica (discreta)	$[0, 100]$
Parental Involvement	Nivel de implicación de los padres en la educación del estudiante.	Categórica (ordinal)	Low, Medium, High
Access to Resources	Disponibilidad en recursos educativos.	Categórica (ordinal)	Low, Medium, High
Extracurricular Activities	Participación en actividades extraescolares.	Categórica (binaria)	Yes, No
Sleep Hours	Número medio de horas de sueño por noche.	Numérica (discreta)	$[0, \infty)$
Previous Scores	Puntuaciones en exámenes previos.	Numérica (discreta)	$[0, 100]$
Motivation Level	Nivel de motivación del estudiante.	Categórica (ordinal)	Low, Medium, High
Internet Access	Disponibilidad de acceso a internet.	Categórica (binaria)	Yes, No
Tutoring Sessions	Número de sesiones de tutoría recibidas por mes.	Numérica (discreta)	$[0, \infty)$
Family Income	Nivel de ingresos familiares.	Categórica (ordinal)	Low, Medium, High
Teacher Quality	Calidad de los docentes.	Categórica (ordinal)	Low, Medium, High
School Type	Tipo de escuela asistida.	Categórica (binaria)	Public, Private
Peer Influence	Influencia de los compañeros en el rendimiento académico.	Categórica (ordinal)	Positive, Neutral, Negative
Physical Activity	Número medio de horas de actividad física por semana.	Numérica (discreta)	$[0, \infty)$
Learning Disabilities	Indica si el estudiante tiene dificultades de aprendizaje.	Categórica (binaria)	Yes, No

Parental Education Level	Nivel educativo más elevado alcanzado por los padres.	Categórica (ordinal)	High School, College, Post-graduate
Distance from Home	Distancia desde el hogar hasta la escuela.	Categórica (ordinal)	Near, Moderate, Far
Gender	Género del estudiante.	Categórica (binaria)	Male, Female
Exam Score	Calificación obtenida en el examen final.	Numérica (discreta)	[0, 100]

3. Descriptiva Univariante

3.1. Análisis descriptivo univariante inicial

A continuación procederemos a hacer un análisis descriptivo univariante de todas las variables, tanto las numéricas como categóricas. Tenemos un total de 7 variables numéricas y otras 13 categóricas. Como se puede observar en el Rmd que adjuntamos con el trabajo, la mayoría de imágenes visuales son muy parecidas en gran parte de las variables, de manera que destacaremos únicamente unas cuantas de ellas, las que consideremos distintas o más relevantes.

3.1.1. Variables numéricas

Para el análisis de las variables numéricas, utilizaremos principalmente los gráficos de *boxplot* e histogramas. La mayoría tienden a seguir una distribución normal, aunque con algunas excepciones. Por ejemplo, las variables *Hours_Studied*, *Sleep_Hours* y *Physical_Activity* presentan distribuciones muy similares (Figura 5).




Figura 5: *Boxplot* e Histogramas de las variables *Hours_Studied*, *Sleep_Hours* y *Physical_activity*

Los datos indican que tanto la asistencia como las calificaciones previas de los estudiantes presentan una variabilidad considerable. No hay una tendencia clara en la que la mayoría tenga valores similares, sino que se observa una distribución amplia: algunos estudiantes asisten a todas las clases, otros apenas van, y muchos tienen un nivel intermedio con diferencias notables entre ellos (véase la Figura 6).

Lo mismo ocurre con las calificaciones previas, donde hay quienes obtienen puntajes muy altos, otros muy bajos y un grupo intermedio con valores bastante dispersos. En un gráfico, esto se reflejaría en una distribución más extendida, sin una concentración marcada en un solo rango de valores.

Fijándonos en la variable *Exam_Score*, los gráficos (Figura 7) indican que la mayoría de los puntajes se concentran entre 60 y 75, con una mediana cercana a 65-70, lo que coincide con la media de la variable ($\mu_{exam_score} = 67,24$). Su *boxplot* muestra un rango intercuartílico estrecho, pero también la presencia de numerosos valores atípicos, especialmente en el rango superior [80, 100].




Figura 7: *Boxplot* e Histograma de la variable *Exam_Score*

Los valores atípicos se identifican mediante la regla del rango intercuartílico (*IQR rule*), que establece límites basados en los cuartiles. Se calcula el IQR como la diferencia entre el tercer cuartil (Q3) y el primero (Q1), y cualquier valor fuera del rango $Q1 - 1,5IQR$ y $Q3 + 1,5IQR$ se considera atípico. Estos valores pueden representar errores, anomalías o casos poco comunes dentro del conjunto de datos.

El histograma confirma una distribución sesgada a la derecha, con pocos estudiantes obteniendo puntajes excepcionalmente altos y algunos valores atípicos en el extremo inferior, aunque en menor medida.

3.1.2. Variables categóricas

Ahora analizamos las variables categóricas, comenzando por la presentación de tablas que muestran tanto las frecuencias absolutas como las relativas, permitiéndonos visualizar la distribución de los valores. Dado que el conjunto de datos ha sido previamente preparado, la mayoría de las variables siguen una lógica esperada, sin valores inesperados o anomalías significativas. Por ejemplo para *Parental_Involvement*, la primera variable, tenemos el Cuadro 4:

Parental-involving	Freq	Frec. relativa
High	1908	0.289
Low	1337	0.202
Medium	3362	0.509

Cuadro 4: Tabla de frecuencias de la variable *Parental_Involvement*




Figura 6: *Boxplot* e Histograma de la variable *Attendance*

Como mencionamos anteriormente, dado que el conjunto de datos ya está preparado, la mayoría de los valores se distribuyen de manera lógica y sin grandes sorpresas. En este caso, por ejemplo, es comprensible que la mayoría de los padres (algo más del 50 %) muestren una preocupación moderada por sus hijos, clasificada como *Medium*. El resto se divide entre aquellos que están muy involucrados en su educación y aquellos que, en cambio, tienden a desentenderse un poco más de sus responsabilidades, como suele pasar en las escuelas de forma general.

Para el análisis gráfico univariante categórico, utilizaremos *barplots* y *pie charts*. Dichas herramientas son clave para visualizar la distribución de variables categóricas, permitiendo identificar patrones y diferencias entre categorías de manera intuitiva. Mientras que el *barplot* muestra comparaciones directas en términos de frecuencia, el *pie chart* resalta la proporción relativa de cada categoría en el conjunto de datos.

En el caso de *Family_Income* visible en la Figura 8, las categorías *Low* y *Medium* tienen proporciones muy similares (40.4 % cada una), mientras que la categoría *High* es significativamente menor (19.2 %). Esto indica que la mayoría de los estudiantes provienen de familias con ingresos bajos o medios, lo que podría influir en aspectos como el acceso a recursos educativos.




Figura 8: *Barplot* y *pie chart* de la variable *Family_Income*

Es comprensible que la mayoría de los padres se ubiquen en las categorías *Low* y *Medium*, ya que estas representan a la mayor parte de la población en términos de ingresos familiares. Esto refleja una realidad en la que la mayoría de los hogares cuentan con recursos económicos limitados o moderados, lo que puede influir en diversos aspectos, como el acceso a materiales educativos o el nivel de apoyo académico brindado a los estudiantes. En contraste, el grupo de familias con ingresos altos es considerablemente menor, apenas un 20 %. Esta diferencia en la distribución sugiere que las oportunidades y condiciones económicas no están equitativamente repartidas, lo que podría tener implicaciones en el desempeño académico y en las posibilidades de los estudiantes para acceder a mejores puestos de trabajo en un futuro no muy lejano.

Para *Internet_Access*, se observa una diferencia, presente en la Figura 9, mucho más marcada, con un 92.4 % de estudiantes que sí tienen acceso y solo un 7.6 % sin él. Esto sugiere que la conectividad no es un problema significativo para la mayoría,

aunque el grupo sin acceso podría enfrentar dificultades en su aprendizaje, especialmente en entornos digitales. Es un hecho ampliamente reconocido que los niños reciben teléfonos móviles a edades cada vez más tempranas, lo que les permite acceder a internet y estar conectados desde muy pequeños. Esta tendencia puede ofrecer numerosos beneficios, como el acceso a información y herramientas educativas, pero también conlleva riesgos significativos, como la exposición a contenidos inapropiados o la dependencia digital.




Figura 9: *Barplot* y *pie chart* de la variable *Internet_Access*

3.2. Preprocesamiento de datos

Para poder explorar nuestros datos en mayor profundidad aplicando métodos como el *clustering* necesitamos primero limpiarlos. El preprocessing consiste en tratar los missings de la base de datos original y luego tratar los *outliers*. A continuación explicaremos como hemos realizado este proceso.

3.2.1. Tratamiento de *missings*

Sabemos que hay varios tipos de missings: aquellos que son completamente aleatorios (MCAR)[‡], aquellos que lo son parcialmente (MAR) y aquellos que no lo son (MNAR). Por eso nuestro primer paso es hacer el Test de *Little*. Este test es un test de bondad de ajuste basado en una prueba chi-cuadrado, el cual contrasta las hipótesis:

$$\begin{cases} H_0 : \text{Missing Data is MCAR} \\ H_1 : \text{Missing Data is not MCAR} \end{cases}$$

Al hacer el test podemos ver cómo el *p*-valor observado (0.4207465) es mayor a un nivel de significación razonable (por ejemplo 0.05) y, por tanto, no hay evidencia suficiente para rechazar H_0 , lo que indica que los datos faltantes son completamente al azar y, por tanto, los podremos corregir.

[‡]MCAR: Missing Completely at Random, MAR: Missings at Random, MNAR: Missings Not at Random

Ya hemos visto anteriormente que sólo tres variables contienen missings y que éstas son las siguientes categóricas: *Teacher_Quality*, *Parental_Education_Level* y *Distance_from_Home*. Además podemos reafirmarlo con la Figura 10.




Figura 10: Gráficos visualizando los *missings* según las variables.

Para dar un análisis más completo sobre estos datos tenemos los siguientes porcentajes resumidos en el Cuadro 5.

Variables con al menos un <i>missing</i>	3.466021 %
Observaciones con al menos un <i>missing</i>	14.28571 %
<i>Missings</i> Teacher_Quality	1.18 %
<i>Missings</i> Parental_Education_Level	1.36 %
<i>Missings</i> Distance_from_Home	1.01 %
<i>Missings</i> Totales	0.177841 %

Cuadro 5: Tabla con porcentajes de *missings*.

Observamos que los porcentajes son bajos. Sin embargo nos interesa ver cómo estos *missings* influyen en la variable respuesta *Exam_Score* (véase la Figura 11).




Figura 11: Distribución de los datos con NA's y sin ellos, de la variable con más *missings*, *Parental_Education_Level*

Así pues, podemos decir que los NA's tienen una leve influencia en los datos. Mirando la nota del examen, observamos que la muestra con NA's en la variable *Parental_Education_Level_NA* aparentemente tiene una nota más baja.

Una vez hecho este análisis, nos toca imputar valores en los missing values que tenemos en nuestro dataset (ya que al no tener más de un 80 % de missings en alguna variable, no es necesario eliminar esta, sino que podemos corregirlos), primero usaremos el método de imputación manual por la moda.

Seguidamente, llenamos los *missings* con la moda, ya que para nuestras variables

que tienen valores faltantes, es la mejor opción, puesto que son categóricas. En segundo lugar, haremos la imputación por el método *MICE*[§], que consiste en una técnica de imputación múltiple que reemplaza los valores perdidos en un conjunto de datos de manera iterativa mediante modelos predictivos basados en las variables disponibles.

Rellenamos buscando observaciones que se parezcan entre ellas mediante un *decision tree*, al usar el método *MICE* tenemos cinco datasets nuevos sin missings cuya calidad en comparación con el dataset original se presenta en la Figura 12. Para poder comparar vemos las tablas de frecuencias entre el dataset original, la imputación manual con la moda y las imputaciones con *MICE* en el Cuadro 6.

Por homogeneidad, deducimos que el mejor método es el *MICE* y dado que entre las cinco posibilidades que tenemos no hay gran diferencia escogeremos la primera.[¶] A partir de ahora todos los resultados serán realizados con la base de datos *StudentPerformanceFactors-1*.




Figura 12: Gráficos de la imputación de *MICE* sobre la variable *Parental_Education_Level*

Parental_Education_Level	College	High School	Postgraduate
Tablas Originales	1989	3223	1305
Imputación Manual	1989	3313	1305
MICE 1	2018	3265	1324
MICE 2	2026	3259	1322
MICE 3	2017	3272	1318
MICE 4	2014	3270	1323
MICE 5	2016	3277	1314

Cuadro 6: Comparación de métodos de imputación

3.2.2. Tratamiento de *outliers*

Recordamos que para el tratamiento de *outliers* sólo se consideran las variables numéricas. Se presentarán dos análisis: el univariante y el multivariante. También

[§]Multiple Imputation by Chained Equations

[¶]Los gráficos y las tablas con las otras dos variables categóricas son muy similares y las conclusiones son las mismas.

queremos recalcar que si una observación es un *outlier* univariante no implica que aparezca como *outlier* en el análisis multivariante. Además, un dato puede parecer normal si se analiza cada variable por separado, pero al considerar la relación entre ellas, puede revelar anomalías que solo el análisis multivariante puede detectar.

Detección univariante

Tal y como hemos hecho anteriormente realizamos el test *IQR* para detectar datos anómalos. De hecho en este caso consideramos que una observación x es un *outlier* severo si $x \notin [Q1 - 3IQR, Q3 + 3IQR]$.

Concretamente, el código analiza de manera automática cada variable por separado para detectar posibles *outliers*. El resultado es de tres variables con *outliers* (*Hours_Studied*, *Tutoring_Sessions* y *Exam_Score*) cuya intersección es nula; es decir, no hay ninguna observación que aparece repetida como un *outlier* de varias variables. La visualización mediante la Figura 13 nos permite corroborar estos valores extremos, por lo tanto no descartamos ninguna observación en la regla del rango intercuartílico.




Figura 13: *Boxplots* para detección de *outliers*

Detección multivariante

Aquí usaremos varios métodos. Los primeros de ellos usan la distancia de Mahalanobis definida como:

$$D_M(x) = \sqrt{(x - \mu)^T \Sigma^{-1} (x - \mu)} \text{ donde } \mu = \frac{1}{N} \sum_{i=1}^N x_i \text{ y } \Sigma \text{ la matriz de covarianzas.}$$

Tenemos que esta distancia $D_M^2 \sim \chi_p^2$ con p el número de observaciones. Entonces con esta distancia obtenemos tres listas de *outliers*: la primera identificando 190 *outliers* con el método explicado ya implementado en *R*, la segunda aplicando un test chi-cuadrado con *aq.plot* encontrando 60 *outliers*, y la última siendo una implementación manual nuestra de la distancia con un umbral del 0.99 obteniendo 79 observaciones atípicas.

Veamos a continuación un análisis gráfico de estos métodos, basados todos en el mismo concepto.

- Figura 14: Los puntos más alejados de la diagonal y con altas distancias pueden indicar *outliers* multivariados.
- Figura 15: Si los datos siguieran una distribución χ^2 ajustada, deberían alinearse en la diagonal. Sin embargo, los *outliers* muestran una clara desviación, indicando que no siguen la misma distribución que el resto.




Figura 14: Gráfico de las distancias de Mahalanobis y distancias robustas




Figura 15: Gráfico distribución chi-cuadrado y distancias de Mahalanobis

También empleamos el método ajustado de $MVN^{\parallel}$ con el que se identifican los *outliers* buscando puntos alejados de la media, considerando tanto las correlaciones entre variables como la dispersión de los datos: detectamos 73 *outliers*.

De momento, los puntos resaltados en rojo de la Figura 16 representan valores extremos detectados con la distancia de Mahalanobis. Aun así, se observa una relación positiva entre horas de estudio, asistencia y puntuación en el examen, donde la mayoría de los puntos siguen un patrón alineado, indicando una tendencia esperada en los datos.




Figura 16: Gráfico 3D de *Hours_Studied*, *Attendance* y *Exam_Score*

^{||}Mutivariate Normal

Para acabar, empleamos el método *LOF***. El siguiente método es un algoritmo para identificar *outliers* locales comparando las distancias de alcance de un punto y de sus vecinos: es una forma de calcular la densidad local alrededor de una observación. El resultado es un valor para cada individuo, que se considera *outlier* si es significativamente mayor a 1, véase el porqué con la fórmula siguiente,

$$LOF(p) = \frac{\sum_{o \in N_k(p)} \frac{lrd(o)}{lrd(p)}}{|N_k(p)|}$$

donde:

- $N_k(p)$ es el conjunto de los k -vecinos más cercanos de p .
- $lrd(p)$ es la *densidad relativa local* de p , que se define como:

$$lrd(p) = \frac{1}{dist_{alcance}(p)}$$

y la *distancia de alcance* de un punto p con respecto a otro punto o es:

$$dist_{alcance}(p, o) = \max(dist_k(o), d(p, o))$$

donde:

- $dist_k(o)$ es la distancia de alcance de o , es decir, la distancia entre o y su k -ésimo vecino más cercano.
- $d(p, o)$ es la distancia entre los puntos p y o .

Presentamos los resultados gráficamente en la Figura 17. La distribución muestra que la mayoría de los datos tienen un LOF cercano a 1 (lo que indica normalidad), pero existe una cola de valores más altos que són los outliers que hemos controlado y comparado.




Figura 17: Distancias *LOF* y estimación de densidad de los puntajes de *outliers*.

Comparando las listas obtenidas de los *outliers* observamos las siguientes coincidencias: aquellos encontrados por la χ^2 están todos presentes en Mahalanobis manual, 9 de los 15 encontrados con el método LOF coinciden con los *outliers* según χ^2 ; y 12 coinciden con los del Mahalanobis manual.

Sin embargo, una vez encontrado todos los posibles outliers con los métodos expuestos y analizando uno a uno dichas observaciones atípicas hemos decidido conservarlos y no eliminarlos ni tratarlos con NAs. Esto se debe a que

estas observaciones no eran erróneas y presentan casos reales. Dos ejemplos que se encuentran con frecuencia son los alumnos que estudian poco pero que aprueban la asignatura y otros que estudian, asisten a clase, piden varias tutorías, tienen una buena nota en el primer examen pero que en el final no brillan en la nota final.

**Local Outlier Factor

3.3. Análisis univariante después del *preprocessing*

De esta manera, el análisis de nuestros datos antes y después del *preprocessing* son muy parecidos, únicamente difieren en las tres variables categóricas que antes tenían *missings* y que ahora ya no: *Teacher.Quality*, *Parental.Education.Level* y *Distance.from.Home*. Así pues vamos a examinar cómo han cambiado (ligeramente) dichas variables.




Figura 18: *Barplot* y *pie chart* respectivamente de las variables *Teacher.Quality*, *Parental.Education.Level* y *Distance.from.Home* (a la izquierda gráficos antes de limpiar los datos y a la derecha después)

Observamos en la Figura 18 que los cambios en las variables tras haber preprocesado los datos son minúsculos, cosa que no debería sorprender dado el bajo porcentaje de *missings* en la base de datos original.

4. Descriptiva Bivariante

4.1. Análisis descriptivo bivalente inicial

4.1.1. Numéricas vs Numéricas

Para llevar a cabo un análisis multivariante de las variables numéricas de nuestro estudio, comenzaremos con la construcción de una matriz de correlaciones (Figura 19). Esta nos permitirá comparar dos a dos todas las variables numéricas e identificar qué variables presentan una mayor dependencia entre sí y cuáles pueden considerarse independientes.

Al analizar la relación entre las variables explicativas, se observa que sus coeficientes de correlación son cercanos a cero. Esto sugiere que son prácticamente independientes entre sí, lo cual es una ventaja para nuestro estudio. La independencia entre variables explicativas es un requisito fundamental en diversos modelos estadísticos, como los modelos de regresión lineal, ya que evita problemas de colinealidad y mejora la interpretación de los resultados.

Por otro lado, al examinar la relación entre la variable respuesta *Exam_Score* y las variables explicativas numéricas, encontramos resultados altamente significativos. Se observa una correlación positiva con *Previous_Scores*, *Tutoring_Sessions*, *Attendance* y *Hours_Studied*, lo que indica que un aumento en estas variables tiende a estar asociado con un mayor puntaje en el examen.

En particular, la correlación entre *Attendance* y *Exam_Score* es considerablemente alta, con un coeficiente de 0.581, mientras que *Hours_Studied* muestra una correlación de 0.445 con la variable respuesta. Estos valores reflejan una relación positiva clara y sugieren que tanto la asistencia a clases como el tiempo de estudio desempeñan un papel clave en el éxito académico.

En los gráficos de la Figura 20 que se presentan a continuación, se puede visualizar esta tendencia, donde un mayor número de horas de estudio y una mayor asistencia se traducen en un mejor puntaje en el examen. Estos hallazgos respaldan la importancia de la dedicación y la constancia en el rendimiento académico de los estudiantes.




Figura 19: Matriz de correlaciones de las variables numéricas




Figura 20: Gráfico de *Exam_Score* en función de *Hours_Studied* (izquierda) y en función de *Attendance* (derecha)

4.1.2. Categóricas vs Categóricas

En este apartado se realizará un análisis bivalente entre las variables categóricas. El método usado consistirá en compararlas dos a dos, y para cada par realizar su tabla de contingencia, un test de independencia (Test Chi-cuadrado) y un *barplot* múltiple.

Cabe recalcar que, en tener 13 variables categóricas y tenerlas que comparar dos a dos, el total de tablas de contingencia, tests de independencia y *barplots* múltiples se calcula mediante nociones básicas de combinatoria^{††}combinaciones de 13 elementos agrupados de dos en dos, lo que da un total de 78 tablas de contingencia, 78 tests de independencia y 78 *barplots*.

Tablas de contingencia

A continuación se mostrará una tabla de contingencia a modo de ejemplo (Cuadro 7), la cual contiene en el título las dos variables a comparar, aunque los comentarios de las comparaciones entre las variables categóricas se llevarán a cabo mediante los *barplots* múltiples, ya que a parte de tener la misma finalidad que una tabla de contingencia y contener la misma información, el resultado se puede visualizar mucho mejor y facilita el entendimiento de las conclusiones. Aún así, estas tablas de contingencia ayudarán a explicar con más detalle los gráficos que se realizarán más adelante ya que contienen las frecuencias absolutas.

	High	Low	Medium	Total
High	568	413	927	1908
Low	414	231	692	1337
Medium	993	669	1700	3362
Total	1975	1313	3319	6607

Cuadro 7: Tabla de contingencia de *Parental_Involvement* vs *Access_to_Resources*

^{††} $\binom{13}{2} = \frac{13!}{2!11!} = 78$

Test de Independencia

A continuación se realiza un test de independencia o de Chi-cuadrado entre 2 variables categóricas.

Esta prueba realiza un test de hipótesis que mide si las dos variables categóricas son independientes o si, por otro lado, están correlacionadas. Es necesario afirmar que podemos llevar a cabo este test ya que, para cada combinación de niveles de variables categóricas siempre tendremos más de cinco observaciones, premisa que es necesaria para este tipo de prueba.

Para realizar el test de hipótesis usaremos un nivel de significación del 0.05, que es sinónimo a usar un nivel de confianza del 95 %.

Entonces, las hipótesis planteadas son:

$$\begin{cases} H_0 : \text{Las dos variables categóricas son independientes.} \\ H_1 : \text{Las dos variables categóricas no son independientes.} \end{cases}$$

Una vez realizado este test las 78 veces filtraremos los p -valores que sean menores a 0.05 para poder detectar qué variables tienen asociación entre ellas (no son independientes, es decir, se rechaza la hipótesis nula de independencia del Test de Chi-cuadrado). Los resultados que se observan en el Cuadro 8 nos dicen qué pares de variables no son independientes entre sí: el *Parental_Involvement* con el *Access_to_Resources*, el *Access_to_Resources* con el *School_Type*, las *Extracurricular_Activities* con la *Peer_Influence* y, finalmente, el *Motivation_Level* con la *Teacher_Quality*.

#	Variable1	Variable2	p-value
1	Parental_Involvement	Access_to_Resources	0.0414220
18	Access_to_Resources	School_Type	0.0424212
29	Extracurricular_Activities	Peer_Influence	0.0244407
36	Motivation_Level	Teacher_Quality	0.0117091

Cuadro 8: Resultados del test de independencia para las variables filtradas por la significancia de su p -valor

Por tanto, se puede concluir que, en la comparación de estas variables con p -valor inferior a 0.05, se puede esperar que una puede influir en la otra y, por tanto, el conocimiento de una de las variables puede darnos información sobre la otra. En las otras comparaciones de variables con p -valor superior al nivel de significación fijado, se puede concluir que son independientes entre sí y por tanto no están asociadas.

Finalmente, cabe recalcar que esto es un primer análisis sin tener los datos pre-procesados, y los valores y conclusiones del test podrían verse alterados después de una detección de *outliers* o supresión de valores faltantes.

Análisis gráfico bivalente

A continuación se realizará un análisis gráfico bivalente, que se basará principalmente en *Barplots* Múltiples para comparar las variables categóricas. En ciertas ocasiones de este análisis, sobre todo al comentar los gráficos definitivamente, se hará uso de las tablas de contingencia obtenidas al principio de esta sección, ya que estas ilustran el número exacto de casos para cada combinación entre niveles de las variables categóricas (frecuencia absoluta).

Ya que uno de los objetivos de este análisis es identificar las relaciones más significativas entre las variables categóricas de nuestro *Dataset*, y existen 78 combinaciones posibles, es necesario un criterio que permita enfocarse en esas asociaciones más relevantes. En el Test de Independencia anterior se ha podido observar cuáles son los pares con menor independencia y, por tanto, este análisis gráfico se centrará en esas variables con mayor asociación estadística, asegurando un análisis relevante y evitando una sobrecarga de gráficos entre dos variables independientes entre sí, ya que el p -valor del Test de Chi-cuadrado o de Independencia sugiere que su relación es meramente aleatoria.




Figura 22: Distribución entre el *School_Type* y el *Access_to_Resources*

La Figura 22 muestra la relación entre el acceso a recursos y el tipo de escuela. Se observa como el tipo de escuela más usada en nuestro *Dataset* es la pública, sin importar si el acceso a los recursos es alto, bajo o medio. Aún así, y con ayuda de las tablas de contingencia realizadas anteriormente, es fácil observar como un acceso a recursos alto supone un mayor porcentaje de estudiantes en un tipo de escuela privada (32.5 %), mientras que un acceso a recursos medio o bajo supone un porcentaje menor al 29 %.




Figura 21: Distribución entre las *Extracurricular_Activities* y el *Parental_Involvement*

La Figura 21 muestra la relación entre el involucramiento parental y las actividades extracurriculares que realiza el/la estudiante, y se observa como los estudiantes con involucramiento parental medio y bajo tienden a hacer actividades extracurriculares en más de un 60 % (ayuda de las tablas de contingencia), mientras que en estudiantes con involucramiento parental alto ese porcentaje es más bajo.

En los tres niveles de involucramiento parental se observa que hay más estudiantes que hacen más actividades extracurriculares en comparación a los que no las hacen.

En la Figura 23 se observa que, en estudiantes que realizan actividades extracurriculares, la influencia de su entorno que más aparece es la positiva (con más de un 40 % de los estudiantes), mientras que si no realizan actividades extracurriculares la influencia de su entorno que más aparece es la neutral (con casi un 41.5 % de los estudiantes). Es importante observar que, tanto si los estudiantes realizan o no actividades extracurriculares, la influencia negativa en ellos aparece con un porcentaje muy parecido (cercano al 20 % en ambos casos).

En la Figura 24 se observa como la mayoría de estudiantes tienen un nivel de motivación medio, mientras que el nivel de motivación alto es el menos común entre los estudiantes. Se observa en el gráfico que, para estas variables aparecen NA's que pueden sesgar los resultados y ser significativos a la hora de redactar las conclusiones, por lo que una vez después del preprocesamiento podremos comparar las variables de manera más precisa.




Figura 23: Distribución entre las *Extracurricular_Activities* y la *Peer_Influence*




Figura 24: Distribución entre la *Motivation_Level* y la *Quality_Teacher*

4.1.3. Numéricas vs Categóricas

En este apartado se llevará a cabo un análisis bivalente entre las variables categóricas y las variables numéricas. El enfoque consistirá en analizar cada variable categórica con cada variable numérica, generando para cada combinación un *boxplot* múltiple, un histograma múltiple y un resumen estadístico por grupos.

Es importante señalar que, dado que contamos con 13 variables categóricas y 7 variables numéricas, el número total de combinaciones entre variables categóricas y numéricas es de 91 (13 categorías por 7 numéricas). Esto implica que se generarán 91 *boxplots* múltiples, 91 histogramas múltiples y 91 resúmenes estadísticos por grupos.

Boxplots Múltiples

A continuación, se realizará un análisis gráfico bivalente utilizando *Boxplots* Múltiples para comparar las variables numéricas en función de las variables categóricas. Los boxplots son representaciones gráficas que permiten observar cómo se distribuyen los valores numéricos en relación con los diferentes niveles de las va-

riables categóricas. Este gráfico es útil para visualizar la dispersión, la mediana, los rangos intercuartil y los valores atípicos en cada grupo categórico.

El objetivo principal de este análisis es comparar las distribuciones de las variables numéricas a través de los diferentes niveles de las variables categóricas. A continuación presentamos nuestras deducciones obtenidas a través de dichos gráficos.




Figura 25: *Boxplot* del *Exam_Score* según el *Parental_Involvement*




Figura 26: *Boxplot* del *Access_to_Resources* según las *Hours_Studied*

Como se puede observar en el gráfico de la Figura 25, la distribución de las notas de examen varía ligeramente según el nivel de participación de los padres. Se puede observar que la mediana de los puntajes es similar en los tres grupos, aunque los estudiantes con alta participación parental presentan una menor dispersión en comparación con los otros niveles.

Además, en todos los casos existen valores atípicos, indicando que algunos estudiantes obtienen notas significativamente más altas o más bajas que el resto. Sin embargo, no se observa una diferencia marcada que sugiera una relación fuerte entre el nivel de participación de los padres y las notas de examen.

Luego, observamos en la Figura 26, la distribución de las horas de estudio no muestra una diferencia significativa entre los distintos niveles de acceso a los recursos. La mediana de horas estudiadas es similar en los tres grupos, situándose alrededor de las 20 horas.

Además, se pueden identificar varios valores atípicos en los tres niveles, indicando que algunos estudiantes estudian considerablemente más o menos que la mayoría. La dispersión de los datos también es similar en todas las categorías, lo que sugiere que el acceso a recursos no parece ser un factor determinante en la cantidad de horas de estudio dedicadas.

En el gráfico de la Figura 27 se observa que la asistencia de los estudiantes no varía significativamente en función del nivel de implicación parental. La mediana de asistencia es similar en los tres grupos, situándose alrededor del 80 %. Además, la dispersión de los datos es comparable en cada categoría, con rangos de asistencia que van aproximadamente del 60 % al 100 %. No se identifican valores atípicos relevantes, lo que indica que la distribución de la asistencia es homogénea en todos los niveles de implicación parental. Esto sugiere que el nivel de participación de los padres no tiene un impacto evidente en la asistencia de los estudiantes.




Figura 27: *Boxplot* del *Parental_Involvement* según la *Attendance*




Figura 28: *Boxplot* del *Exam_Score* según las *Extracurricular_Activities*

Finalmente, como podemos observar en la Figura 28, las notas de examen presentan una distribución similar entre los estudiantes que participan en actividades extracurriculares y aquellos que no. Sin embargo, la mediana de las notas es ligeramente mayor en los estudiantes que sí que participan en actividades extracurriculares en comparación con los que no participan.

También se aprecia que el grupo de estudiantes que participa en actividades extracurriculares muestra una mayor dispersión en las notas y presenta más valores atípicos en el extremo superior. Esto podría sugerir que, aunque la diferencia no es muy elevada, la participación en actividades extracurriculares podría estar asociada con una mayor variabilidad en las notas de examen y un posible beneficio en el rendimiento académico de algunos estudiantes.

Histogramas Múltiples

A continuación se realizará un análisis gráfico bivalente utilizando Histogramas Múltiples para comparar las variables numéricas en función de las variables categóricas. Los histogramas son herramientas gráficas que permiten observar la distribución de los datos numéricos, mostrando cómo se agrupan o dispersan los valores dentro de diferentes categorías. Este tipo de gráfico es útil para visualizar la forma de la distribución, la frecuencia de los datos en los intervalos definidos y la posible existencia de sesgos o distribuciones inusuales dentro de cada grupo.

El objetivo de este análisis es comparar cómo varían las distribuciones de las variables numéricas entre los distintos grupos definidos por las variables categóricas. Esto permite identificar diferencias clave entre los grupos y proporcionar una interpretación visual de cómo se comportan las variables numéricas en cada categoría. Nuestras deducciones




Figura 29: Histograma de *Exam_Score* según el *Access_to_Internet*

se muestran en los párrafos siguientes.

Como se puede observar en el gráfico de la Figura 29, la distribución de las notas varía según el acceso a internet. La mayor parte de los estudiantes con acceso a internet tiene notas concentradas entre 60 y 75, con un pico de frecuencia cercano a 70. En cambio, los estudiantes sin acceso a internet presentan una menor frecuencia en todos los rangos de notas, lo que indica que son una proporción mucho menor dentro del conjunto de datos.

Se observa que la distribución de los estudiantes con acceso a internet es más pronunciada, lo que sugiere que este grupo tiene una mayor presencia en el análisis. Aunque existen valores atípicos en ambos casos, no se aprecia una diferencia extrema en la distribución de las notas entre quienes tienen y no tienen acceso a internet, más allá de la diferencia en la cantidad de estudiantes en cada grupo.




Figura 30: Histograma de las *Hours_Studied* según el *Family_Income*




Figura 31: Histograma de la *Attendance* según el *School_Type*

Vemos en la Figura 30, la distribución de las horas de estudio varía según el nivel de ingresos familiares. La mayor parte de los estudiantes, independientemente de su nivel de ingresos, tiende a estudiar entre 10 y 30 horas, con un pico de frecuencia alrededor de las 20 horas.

Los estudiantes con ingresos medios (en azul claro) parecen ser el grupo más numeroso y presentan una distribución más homogénea. Por otro lado, los estudiantes con ingresos bajos (en verde) y altos (en rojo, aunque apenas visible en la gráfica) están representados en menor medida.

No se observa una diferencia marcada en la cantidad de horas de estudio según el nivel de ingresos, aunque sí que se puede ver que la mayoría de los estudiantes pertenecen al grupo de ingresos medios, lo que podría ser influyente en la interpretación de los resultados.

Como se puede observar en la Figura 31, la distribución de la asistencia varía según el tipo de escuela. La mayor parte de los estudiantes presentan niveles de asistencia entre 60 y 100, con una distribución relativamente uniforme.

Los estudiantes de escuelas públicas representan la mayoría de la muestra y muestran una variabilidad considerable en los niveles de asistencia. En contraste, los estudiantes de escuelas privadas parecen tener una distribución más homogénea y con menor presencia en los valores más altos de asistencia.

No se observa una diferencia marcada en la asistencia entre los tipos de escuela,

aunque la mayor cantidad de estudiantes atiende escuelas públicas, lo que podría influir en los resultados.




Figura 32: Histograma del *Exam_Score* según las *Extracurricular_Activities*

Nuestro último histograma (Figura 32) muestra la distribución de los resultados en exámenes según la participación en actividades extracurriculares. Se observa que la mayoría de los estudiantes se concentran en el rango de 60 a 75, con algunos casos aislados que superan el valor de 80.

En cuanto a la relación entre la participación en actividades extracurriculares y el desempeño en los exámenes, los estudiantes que participan en estas actividades, representados en color azul, parecen tener una mayor presencia en los niveles más altos. Por otro lado, los estudiantes que no participan, representados en color rojo, aparecen en menor

cantidad en general, aunque están distribuidos en casi todos los rangos.

Esta distribución sugiere que podría haber una leve tendencia a que los estudiantes que participan en actividades extracurriculares obtengan mejores resultados en los exámenes. Sin embargo, la diferencia no es muy marcada y, para confirmar esta observación, sería necesario realizar un análisis estadístico más detallado.

Summary por grupos

En esta sección se generará un resumen estadístico por grupos para cada variable categórica, con el objetivo de calcular estadísticas descriptivas para cada variable numérica según los niveles de las variables categóricas. Las estadísticas calculadas incluyen la media, la desviación estándar, el mínimo y el máximo para cada grupo, proporcionando una visión detallada del comportamiento de las variables numéricas dentro de cada categoría. Esto facilita la interpretación de posibles patrones o diferencias entre los grupos.

Este análisis ayuda a detectar diferencias significativas entre los grupos, permitiendo comprender mejor cómo varían las variables numéricas en función de las categorías. Las tablas pueden consultarse a parte en el archivo *RMD* correspondiente.

En el análisis de *Exam_Score* según *Parental_Involvement*, se ve que los estudiantes con una mayor implicación de los padres tienen un promedio de resultados en los exámenes de 75.3, mientras que aquellos con menos implicación obtienen 74.6. Aunque la diferencia es pequeña, es importante resaltar que los estudiantes con más apoyo parental tienden a tener mejores resultados, aunque la variabilidad en los resultados es similar entre ambos grupos. Esto sugiere que el apoyo de los padres podría tener un impacto positivo en el rendimiento académico, especialmente en los casos más destacados.

En el caso de *Hours_Studied* según *Access_to_Resources*, los estudiantes con mayor acceso a recursos estudian, en promedio, 19.99 horas, mientras que los que tienen acceso limitado estudian unas 20.1 horas. Lo interesante es que, aunque las horas

de estudio son similares, los estudiantes con menos recursos tienen una mayor variabilidad en las horas que dedican al estudio. Esto podría indicar que, en algunos casos, los estudiantes con menos recursos se esfuerzan más para compensar lo que les falta, lo que resalta la importancia de la motivación y el esfuerzo personal.

En *Attendance* según *School_Type*, los estudiantes de escuelas privadas tienen una asistencia promedio de 80.3 %, mientras que los de escuelas públicas alcanzan 79.8 %. Aunque la diferencia es mínima, lo que llama la atención es que las escuelas públicas tienen una mayor cantidad de estudiantes con asistencia baja, lo que podría estar relacionado con factores socioeconómicos o la falta de recursos. Esto es relevante porque una asistencia baja puede influir negativamente en el rendimiento académico.

Finalmente, en *Exam_Score* según *Extracurricular_Activities*, los estudiantes que participan en actividades extracurriculares tienen una media de resultados de 67.9, un poco más alta que los 66.8 de aquellos que no participan. Aunque no hay mucha diferencia, sugiere que estar involucrado en actividades fuera del aula puede ayudar a mejorar el rendimiento académico. También se ve que los estudiantes que no participan tienen una mayor variabilidad en sus resultados.

En resumen, estos sumarios destacan algunos factores importantes que podrían mejorar el rendimiento académico, como el apoyo de los padres, el acceso a recursos, la asistencia escolar y la participación en actividades extracurriculares.

4.2. Análisis descriptivo bivariante de los datos preprocesados

4.2.1. Numéricas vs Numéricas

Después de procesar los datos, se realizó un análisis bivariante para estudiar las relaciones entre las variables numéricas del conjunto de datos. Dado que el preprocesamiento de los datos se centró en la gestión de *missings* en variables categóricas y se conservaron los *outliers* debido a su relevancia contextual, los resultados del análisis bivariante numérico permanecen invariantes respecto a los obtenidos antes del procesamiento.

Puesto que los resultados del análisis permanecen inalterados, se mantienen las conclusiones originales. En este contexto, resalta la independencia entre las variables explicativas, la moderada correlación de *Previous_Scores* y *Tutoring_Sessions* con la variable respuesta *Exam_Score*, y, finalmente, la fuerte asociación que muestran *Hours_Studied* y *Attendance* con el rendimiento académico.

4.2.2. Categóricas vs Categóricas

Esta parte del trabajo se centra en realizar un análisis bivariante de los datos categóricos de la misma manera que se ha hecho en un anterior apartado, con la diferencia que en este caso se realiza para los datos preprocesados.

Siguiendo el mismo procedimiento, ahora con nociones básicas de combinatoria podemos concluir que tendremos un total de 33^{††} gráficos diferentes a los del análisis bivariante inicial sin los datos preprocesados.

^{††} $\binom{3}{2} + 3 \times (13 - 3) = 33$

Cabe recalcar que las variables que contenían *missings* eran 3 (*Teacher_Quality*, *Distance_from_Home* y *Parental_Education_Level*), y por tanto en este apartado son las que nos interesan principalmente y en las que nos centraremos.

Tablas de contingencia#

Estas tablas, las cuales contienen las frecuencias absolutas de cada combinación de variables categóricas y sus totales, nos servirán para comentar exhaustivamente los gráficos bivariantes (*barplots* múltiples).

Test de Independencia

Siguiendo la misma metodología que con los datos sin preprocesar, y afirmando que el test de independencia puede llevarse a cabo ya que el número de observaciones para cada combinación de variables es superior a 5, podemos observar que los valores del estadístico 2 han cambiado respecto al test sin los datos preprocesados, y por tanto también el p -valor. Aún así, lo que nos interesa estudiar y observar es si algún p -valor se ha vuelto significativo y, por tanto, si se puede concluir que algún par de variables tienen asociación. Filtrando los tests de independencia según si su p -valor es inferior a 0.05 obtenemos el Cuadro 9.

#	Variable1	Variable2	p-value
10	Motivation_Level	Teacher_Quality	0.0086147

Cuadro 9: Resultados del test de independencia después del preprocessing filtrados por la significancia de su p -valor

Observamos que son el par de variables que ya nos aparecía en el test de los datos sin preprocesar, y aunque el p -valor es menor que el que obtuvimos en el anterior análisis, la conclusión del test es la misma (El nivel de motivación y la Calidad del Profesor no son independientes).

Por tanto, las conclusiones de la prueba son las mismas con los datos preprocesados, cuestión que puede deberse a la poca frecuencia de *missings* observados al inicio del estudio.

Análisis gráfico bivalente

En este apartado, nos centramos en realizar gráficos bivariantes (*barplots* múltiples) para comparar las variables categóricas. Aquí, se generan 33 gráficos a modo de comparación entre las variables categóricas, en los que siempre aparece una de las tres variables categóricas de interés.

Como es necesario fijar un criterio para comentar los gráficos más relevantes, nos centraremos en comentar los *barplots* entre variables que tienen una cierta asociación, estudiada en el Test de Independencia. Aún así, como solo nos ha salido un p -valor inferior a 0.05, también se comentarán a continuación los gráficos entre

las variables que inicialmente tenían *missings*, ya que ahora en esas casillas tienen valores imputados mediante el algoritmo *MICE*.



Figura 33: Distribución entre *Motivation_Level* y *Teacher_Quality*




Figura 34: Distribución entre *Distance_from_Home* y *Teacher_Quality*

Como se puede observar en el gráfico de la Figura 33, y en comparativa con el mismo que se hizo con los *missings* presentes en el *Dataset*, lo primero que se observa es que ya no existen estos NA's. Cabe recalcar que la mayoría de estudiantes tienen un nivel de motivación medio, mientras que el nivel de motivación alto es el menos común entre los estudiantes, de la misma forma que sucedía en el primer análisis.

En la Figura 34 se observa que la gran mayoría de los estudiantes viven cerca de la escuela (60%), y el comportamiento general es que la calidad del profesor no depende de la distancia que estos alumnos viven de la escuela, ya que como observamos en las 3 categorías de *Teacher_Quality* tenemos distribuciones muy parecidas. Vemos también que la calidad más frecuentada del profesor es media.

Esta distribución similar entre categorías también es explicada por el Test 2, ya que el p -valor entre estas dos variables era muy elevado (0.86), y por tanto son independientes.




Figura 35: Distribución entre *Parental_Education_Level* y *Teacher_Quality*




Figura 36: Distribución entre *Distance_from_Home* y *Parental_Education_Level*

Como se observa en el gráfico anterior (Figura 35 y resultado directo de que estas dos variables eran independientes en el Test de Independencia), podemos concluir

que la educación de los padres de los estudiantes es independiente a la calidad del profesor, y se observa una distribución muy parecida entre categorías. Recaltar que la categoría que más se repite en los padres de los estudiantes es *High School* (50 %).

En el *barplot* múltiple anterior de la Figura 36 se observa la misma tónica que en los dos últimos comentados, ya que mediante el Test de Independencia se ha observado que las dos variables son independientes, independientemente de que contuvieran *missings*.

Por tanto, se observan las distribuciones e independientemente de la categoría del nivel de educación parental, la distancia desde casa al colegio de los estudiantes es cercana en un 50 % de los estudiantes dentro de cada categoría

4.2.3. Numéricas vs Categóricas

En esta sección del trabajo, se realiza un análisis bivalente entre las variables categóricas y las variables numéricas, siguiendo el mismo enfoque que en el apartado anterior, pero con los datos preprocesados. Es fundamental destacar que en este caso, los valores faltantes han sido imputados mediante el algoritmo MICE, lo que ha permitido rellenar los valores ausentes de manera efectiva. No obstante, los valores atípicos no han sido eliminados, ya que se considera que estos valores son significativos en el contexto del estudio como se ha comentado anteriormente.

Cabe recalcar que las variables que contenían valores faltantes en el conjunto de datos original eran 3: *Teacher_Quality*, *Distance_from_Home* y *Parental_Education_Level*. Por lo que, serán las variables en las que nos centraremos en este apartado.

Al seguir el mismo procedimiento que en el análisis anterior con los datos sin preprocesar, se generarán un total de 21 combinaciones entre las variables categóricas y las numéricas. Esto se debe a que existen 3 variables categóricas y 7 variables numéricas, lo que resulta en 21 combinaciones en total (3 categorías por 7 numéricas). Para cada combinación, se generarán los siguientes gráficos y análisis: *boxplots* múltiples, histogramas múltiples y resúmenes estadísticos.

Boxplots Múltiples

En este apartado, nos centramos en realizar gráficos bivariantes usando *boxplots* múltiples para comparar las variables numéricas en función de las variables categóricas, pero en este caso, con los datos preprocesados.

El objetivo principal de este análisis es comparar cómo varían las distribuciones de las variables numéricas entre los distintos niveles de las variables categóricas y observar cómo la imputación de valores faltantes afecta.

En el gráfico (Figura 37) se observa que los resultados en los exámenes no presentan diferencias marcadas según la calidad del profesor. La mediana de cada grupo es similar, situándose alrededor de 70, lo que indica que en términos generales, los estudiantes obtienen resultados parecidos independientemente de si sus profesores son considerados de alta, media o baja calidad.

Aun así, se pueden notar algunas diferencias en la dispersión de los datos. Aunque los tres grupos presentan una distribución relativamente similar, la categoría de calidad media parece tener una ligera menor dispersión, con un rango menos amplio

de valores. En todas las categorías se identifican valores atípicos, especialmente en los niveles más altos, donde algunos estudiantes alcanzan puntuaciones cercanas a 100. Esto sugiere que, aunque la calidad del profesor podría influir en algunos casos, no parece ser el único factor determinante en los resultados obtenidos por los estudiantes.




Figura 37: Distribución entre *Teacher_Quality* y *Exam_Score*

Figura 38: Distribución entre *Parental_Education_Level* y *Exam_Score*

En la Figura 38 se observa que los resultados en los exámenes no presentan una diferencia considerable según el nivel educativo de los padres. Las medianas de los tres grupos son similares, situándose alrededor de 70, lo que indica que generalmente, los estudiantes obtienen notas parecidas independientemente del nivel educativo de los padres.

Sin embargo, se pueden notar algunas variaciones en la dispersión de los datos. Los estudiantes cuyos padres tienen educación de posgrado presentan una ligera tendencia a obtener resultados más altos en comparación con los otros grupos, con una mediana apenas superior. Además, este grupo muestra una menor dispersión, lo que sugiere una mayor concentración de calificaciones en torno al valor central. En los tres grupos se identifican valores atípicos en ambos extremos, con algunos estudiantes alcanzando calificaciones muy altas y otros obteniendo calificaciones significativamente más bajas. Esto sugiere que aunque el nivel educativo de los padres podría influir en cierto grado, no parece ser un factor determinante en los resultados.

El gráfico de la Figura 39 muestra la relación entre la asistencia de los estudiantes y la distancia de su casa a la escuela. No parece haber una diferencia significativa entre los grupos, ya que la mediana de asistencia se mantiene en torno al 80 % en todos los casos, aunque se puede apreciar una mediana ligeramente inferior en los estudiantes que viven lejos de la escuela. Esto sugiere que, en general, la distancia no es un factor que afecte drásticamente la cantidad de clases a las que los estudiantes asisten.

Además, al observar la dispersión de los datos, podemos observar que los tres grupos presentan rangos de asistencia similares, desde aproximadamente un 60 % hasta un 100 %.

Como podemos observar en la Figura 40, la distribución de los datos es bastante homogénea en los tres grupos, con rangos similares. Esto indica que la mayoría de




Figura 39: Distribución entre *Attendance* y *Distance_from_Home*




Figura 40: Distribución entre parental education y hours studied

los estudiantes, sin importar el nivel educativo de los padres, estudian aproximadamente la misma cantidad de horas. Sin embargo, se observan valores extremos tanto en la parte inferior como en la superior de cada grupo. Hay estudiantes que registran muy pocas horas de estudio (cercanas a 0) y otros que estudian más de 40 horas. Además, la variabilidad en las horas de estudio es similar para todos los niveles educativos de los padres.

Podemos concluir que el nivel de educación de los padres no es un factor determinante en el tiempo de estudio de los hijos, ya que las medianas y la dispersión de los datos son prácticamente iguales. Además, la presencia de valores atípicos indica que algunos estudiantes tienen hábitos de estudio que se desvían del patrón general.

Histogramas Múltiples

A continuación, se realizará un análisis gráfico bivalente utilizando Histogramas Múltiples para comparar las variables numéricas en función de las variables categóricas, pero con los datos preprocesados.

Como se puede observar en el gráfico (Figura 41), la distribución de las calificaciones del examen varía según la calidad del docente. La mayoría de los estudiantes tienen calificaciones entre 60 y 75, con un pico alrededor de 70, lo que indica que la mayor parte de las calificaciones se encuentran en este rango. Los estudiantes con docentes de calidad media representan la mayor parte de la muestra y muestran una distribución más amplia en este rango. En cambio, los estudiantes con profesores de baja calidad presentan una mayor dispersión, aunque también están concentrados en la misma franja de notas. El número de estudiantes con profesores de alta calidad es menor en la muestra y, aunque su distribución es similar, parecen tener una ligera tendencia a obtener mejores resultados.

No se observa una diferencia significativa en las notas según la calidad del docente, aunque la mayor proporción de estudiantes con docentes de calidad media podría ser influyente en la interpretación de los resultados.

Como se puede observar en el gráfico de la Figura 42, la distribución de las calificaciones del examen varía según el nivel educativo de los padres. La mayoría de los estudiantes obtienen notas entre 60 y 75, con un pico de frecuencia alrededor




Figura 41: Histograma entre *Exam_Score* y *Teacher_Quality*




Figura 42: Histograma entre *Exam_Score* y *Parental_Education_Level*

de 70, lo que sugiere una alta concentración de estudiantes en este rango. Los estudiantes cuyos padres tienen un nivel educativo de secundaria representan la mayor parte de la muestra y muestran una distribución más amplia. En cambio, los estudiantes con padres que han cursado estudios universitarios o de posgrado son menos numerosos, aunque mantienen una distribución similar. No se observa una diferencia marcada en los resultados según el nivel educativo de los padres, aunque la mayor proporción de estudiantes con padres que solo han cursado la secundaria podría estar influyendo en la interpretación de los resultados.




Figura 43: Histograma entre *Attendance* y *Distance_from_Home*




Figura 44: Histograma entre *Parental_Education_Level* y *Hours_Studied*

Como podemos observar en el histograma (Figura 43), la mayoría de los estudiantes presentan niveles de asistencia entre 60 y 100, aunque la distribución exhibe un patrón irregular con picos de frecuencia a lo largo del eje. En términos de cantidad, los estudiantes que viven cerca de la escuela representan la mayor parte de la muestra, con una distribución relativamente estable en todos los niveles de asistencia. Esto sugiere que la proximidad a la escuela podría estar asociada con una mayor regularidad en la asistencia. Los estudiantes cuya distancia al hogar es moderada presentan un patrón similar, aunque en menor proporción. Por otro lado, los estudiantes que viven lejos tienen una representación muy baja en el gráfico, lo que podría indicar una menor cantidad de alumnos en esta categoría.

o dificultades para mantener una asistencia constante debido a la distancia, como tiempos de traslado largos o problemas de transporte.

Se observa en la Figura 44 que la mayoría de los estudiantes dedican entre 10 y 30 horas semanales al estudio, con una distribución aproximadamente simétrica y un pico en torno a las 20 horas. La cantidad de estudiantes disminuye tanto en valores muy bajos (menos de 5 horas) como en valores muy altos (más de 35 horas), lo que sugiere que la dedicación extrema al estudio es menos común.

No se observan diferencias drásticas entre los grupos, aunque se aprecia que los estudiantes con padres de mayor nivel educativo tienden a distribuirse de manera más homogénea en los distintos niveles de estudio.

Summary por grupos

En esta sección, se generará un resumen estadístico por grupos para cada variable categórica con el objetivo de calcular estadísticas descriptivas para cada variable numérica, considerando los niveles de las variables categóricas, como en el apartado anterior pero ahora con los datos preprocesados.

En cuanto a la calidad del profesor, no se han observado diferencias significativas en las horas de estudio entre los distintos niveles, con promedios que se mantienen alrededor de 19.9 y 20.0 horas. La asistencia escolar también ha mostrado valores similares en todos los grupos, situándose alrededor del 80 %, sin variaciones destacadas. Sin embargo, al analizar los resultados académicos, se ha visto que los estudiantes con profesores de mayor calidad obtuvieron *Previous_Scores* ligeramente superiores en comparación con los demás grupos, aunque la diferencia no ha sido distintiva. De manera similar, *Exam_Score* ha presentado una leve tendencia a ser más alta en los estudiantes con profesores de mejor calidad, lo que podría sugerir una relación entre la calidad del docente y el rendimiento académico.

Por otro lado, el nivel educativo de los padres tampoco ha mostrado una influencia clara en las horas de estudio, con valores promedio muy similares en todos los niveles educativos. Aún así, sí que se observó una ligera diferencia en la asistencia escolar, siendo algo mayor en los estudiantes cuyos padres alcanzaron un nivel educativo de posgrado, con un promedio del 80.5 %. En relación con los resultados académicos, los estudiantes con padres de educación superior tienden a obtener *Exam_Score* ligeramente más altas, con una media de 67.9, en comparación con aquellos cuyos padres solo han finalizado la educación secundaria, cuya media fue de 66.9. A pesar de esta diferencia, no se puede concluir que exista una relación fuerte entre el nivel educativo de los padres y el rendimiento académico, ya que las variaciones entre grupos han sido mínimas.

En cuanto a la distancia desde casa hasta el colegio, se ha observado una leve tendencia en la que los estudiantes que viven más lejos parecen dedicar un poco más de tiempo al estudio, con un promedio de 20.1 horas, aunque la diferencia con los demás grupos es mínima. Respecto a la asistencia, se ha encontrado que los estudiantes que residen más cerca de la escuela presentan una asistencia ligeramente superior, alcanzando el 80.1 %, en comparación con aquellos que viven lejos, que registran un 79.5 %. En lo que respecta a los resultados académicos, los estudiantes que viven cerca del colegio obtienen en promedio un *Exam_Score* de 67.5, mientras

que aquellos que viven lejos presentan una media de 66.4. Sin embargo, en otras variables como las horas de sueño, las sesiones de tutoría o la actividad física, no se han observado diferencias notables en función de la distancia al colegio.

En general, este análisis confirma que la imputación de valores faltantes no ha alterado significativamente los patrones previos y que las relaciones entre variables categóricas y numéricas se mantienen estables con los datos preprocesados. Aunque se han identificado algunas tendencias, como una leve mejora en la asistencia y el rendimiento académico en estudiantes con profesores de mayor calidad o con padres con educación superior, las diferencias no son lo suficientemente marcadas como para establecer una relación fuerte. Esto sugiere que, aunque factores como la calidad del profesor, la educación parental o la distancia al colegio pueden influir en el desempeño académico, su impacto no es determinante por sí solo y debe analizarse en conjunto con otros elementos que afectan el aprendizaje de los estudiantes.

5. Clustering

5.1. Clustering particionales

5.1.1. Selección del k -óptimo

En este apartado del trabajo, el objetivo principal es determinar el valor de k -óptimo, es decir, el número de *clusters* óptimo. Para alcanzar este objetivo, se realizarán los códigos pertinentes y se usarán los métodos que se exponen a continuación:

- *Elbow method* (Método del “codo”)
- *(Average) Silhouette method*
- *Gap statistic*
- Índice de Calinski-Harabasz

Después de esta elección de k , se pasará a la selección y uso de diferentes métodos particionales, como por ejemplo *k-Means*.

Elbow method

Consiste en computar un algoritmo de *clustering* para diferentes valores de k (valores comprendidos entre el 1 y el 10). Para cada k , se calcula la suma de cuadrados total dentro de cada *cluster*, se grafica la curva para cada valor y finalmente se busca el punto en el que el pendiente se reduce significativamente (véase la Figura 45).




Figura 45: Varianza total de los datos en función del número de *clusters* k

Como se puede observar en el gráfico anterior, el SSE disminuye a medida que aumenta el valor de k , pero la forma de “codo” puede intuirse que se toma en el valor $k = 4$ y, por ende, podemos considerar que el número óptimo de *clusters* es 4. Cabe recalcar que, aunque la suma de cuadrados sería menor si aumentamos los *clusters*, esto supone un coste computacional mucho más elevado, y se toma el valor de cuatro *clusters* como óptimo para el Método del Codo.

Silhouette method

Este método consiste en que, dados k *clusters*, para cada individuo i se calcula:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \in [-1, 1]$$

Donde $a(i)$ es la distancia media desde i hasta todos los individuos del mismo *cluster* y $b(i)$ es la menor distancia media desde i hasta todos los individuos de cualquier otro *cluster*. Por tanto, este método mide la similitud de cada objeto en su propio grupo en comparación con otros grupos.




Figura 46: *Silhouette* media de los datos en función del número de *clusters* k




Figura 47: Coeficiente de *silhouette* en función del número de *clusters* k

Este *plot* de la Figura 46 nos muestra que el número de *clusters* óptimo son 2, ya que es donde se alcanza el valor máximo del índice de silueta. De manera análoga y usando el paquete *ggplot2*, aunque necesariamente usando un bucle y fijando una k inicial para poder usar el algoritmo *k-Means*, se obtiene el gráfico de la Figura 47, que muestra exactamente lo mismo que el anterior y se concluye que para el método de la silueta el número óptimo de *clusters* es 2.

Gap Statistic

Este método para la selección del k -óptimo se basa en comparar la SSE para el *clustering* observado con la SSE esperada para un conjunto de datos aleatorios de referencia. El número óptimo de *clusters* se elige como aquel que maximiza la diferencia entre las SSE observadas y las SSE esperadas.




Figura 48: El GAP estadístico en función del número de *clusters* k

Entonces, tal y como se puede observar en la Figura 48, aunque el valor de Gap_k se va maximizando a medida que aumenta el número de clústers, se concluye que en $k = 4$ se estabiliza este crecimiento, similar a un comportamiento logarítmico. Por tanto, como aumentar k en varias unidades supondría un aumento poco significativo de Gap_k y, en cambio, un aumento computacional más elevado, se interpreta que el número óptimo de *clusters* mediante el método del *Gap Statistic* es de 4, igual que en el Método del Codo.

Índice de Calinski-Harabasz

Este método mide la relación entre la dispersión dentro de cada grupo y la dispersión entre los grupos.

Un valor más alto de este índice indica una mejor separación entre los grupos. El índice se calcula como:

$$CH(k) = \frac{S_b/k - 1}{S_w/n - k},$$

siendo S_b la variancia entre *clusters* y S_w la variancia total.

Evidentemente, los *clusters* bien definidos tendrán que tener S_b alta y S_w baja.

En la Figura 49, el valor del índice empieza a decrecer drásticamente a partir de $k = 4$, y por tanto 4 es el número de *clusters* óptimo




Figura 49: Índice de Calinski Harabasz en función del número de clústers k

que nos indica el índice de Calinski-Harabasz.

Resumen de resultados

Finalmente, después de haber aplicado estos cuatro algoritmos, se busca encontrar qué valor de k es el óptimo y más verosímil en nuestro contexto. Observando los resultados de los algoritmos anteriores, concluimos que tres de ellos nos indican que el valor óptimo de *clusters* es 4, mientras que solo el método de la silueta nos indica $K = 2$.

Por tanto, mediante un razonamiento estadístico básico, nos fijamos en el valor de la moda de estos cuatro algoritmos, y en este caso se concluye que el número de *clusters* óptimo para realizar un método de *clustering* particional por *k-means* es de $K = 4$.

5.1.2. Selección de diferentes métodos particionales

En este apartado del trabajo, después de haber determinado el número de *clusters* k -óptimo en el apartado anterior, el objetivo principal es aplicar diferentes métodos particionales para realizar el agrupamiento (*clustering*) de los datos. Los métodos particionales dividen el conjunto de datos en k grupos o *clusters*, donde cada observación pertenece a un solo *cluster*, y cada *cluster* está definido por sus características particulares. Los métodos particionales que hemos usado en este análisis han sido *k-means*, PAM y CLARA.

k-Means

El *k-means* es uno de los métodos de *clustering* más utilizados debido a su simplicidad y eficiencia. Su objetivo es dividir un conjunto de datos en k *clusters*, donde k es el número de *clusters* que se debe definir previamente. El algoritmo comienza con la asignación aleatoria de los centroides.

Cada *cluster* tiene un centroide que se calcula como el promedio de todas las observaciones dentro de ese *cluster* para cada variable numérica. A continuación, el algoritmo asigna cada punto de datos al *cluster* cuyo centroide esté más cercano, utilizando la distancia euclidiana como medida de cercanía entre los puntos y los centroides. Una vez que los puntos se asignan a los *clusters*, se recalculan los centroides de cada grupo, ya que ahora los *clusters* han cambiado. Este proceso de asignación de puntos a *clusters* y recalculación de centroides se repite iterativamente hasta que las asignaciones de los puntos a los *clusters* ya no cambian, es decir, hasta que el algoritmo alcanza una solución estable.

Aunque los *clusters* están diferenciados por colores y formas, hay una superposición significativa entre ellos, lo que sugiere que los datos no están completamente separados en grupos distintos. Se observa en la Figura 50 que los *clusters* 1 (rojo) y 3 (azul) tienen una mayor dispersión en el eje X, mientras que el *cluster* 4 (morado) parece más concentrado.

Las elipses indican la distribución de los datos dentro de cada *cluster*. Se observa que




Figura 50: Visualización de los clústers con el método k-means

los *clusters* tienen una alta superposición, lo que sugiere que los centroides pueden estar cercanos entre sí y que los grupos no son completamente homogéneos.

Los ejes muestran los porcentajes de varianza explicada por cada dimensión (Dim1: 25.2% y Dim2: 15%), lo que indica que una gran parte de la información aún se encuentra en dimensiones no representadas en este gráfico.

PAM (Partitioning around medoids)

PAM (*Partitioning Around Medoids*) es un algoritmo similar a *k-means*, pero con una diferencia clave en la forma en que se definen los clústers. Mientras que *k-means* utiliza centroides (que son los promedios de los puntos dentro de cada clúster) para representar el centro de cada grupo, PAM utiliza un medoide, que es un punto de datos real dentro del clúster que mejor representa el centro de ese grupo. El uso del medoide en lugar de un centroide ofrece varias ventajas, especialmente cuando los datos contienen valores atípicos. Los centroides pueden verse muy afectados por puntos que están muy alejados de los demás datos (valores extremos o *outliers*), lo que puede distorsionar la representación del centro de un *cluster*. En cambio, el medoide, al ser un punto real de los datos, es menos sensible a los valores atípicos, lo que hace que PAM sea más robusto y adecuado cuando los datos incluyen puntos atípicos que podrían afectar a los resultados de *clustering* utilizando *k-means*.

El algoritmo PAM, al igual que *k-means*, busca asignar cada punto de datos a un *cluster* de tal forma que minimice la suma de las distancias entre los puntos de datos y el medoide correspondiente dentro de cada *cluster*. Para medir estas distancias, hemos utilizado la distancia de Gower, que es especialmente útil cuando se trabaja con datos mixtos que contienen tanto variables numéricas como categóricas. La distancia de Gower permite calcular similitudes entre observaciones con diferentes tipos de variables, asegurando que todas ellas contribuyan adecuadamente al proceso de

clustering. Este proceso de minimización continúa iterativamente, con el algoritmo reajustando las asignaciones de los puntos y los medoides hasta que las asignaciones no cambian más.

El gráfico de la Figura 51 muestra la agrupación de datos obtenida con el método PAM y la distancia de Gower. Se observan cuatro *clusters* diferenciados por color y forma, pero con una fuerte superposición entre ellos.

Las elipses de los *clusters* se solapan considerablemente, lo que indica que no hay una separación clara entre los grupos. La densidad de puntos en el centro sugiere que gran parte de los datos están distribuidos de manera similar en el espacio reducido, lo que dificulta la diferenciación visual entre los *clusters*. En general, la representación gráfica no muestra fronteras bien definidas entre los grupos.




Figura 51: Visualización de los *clusters* con el método PAM

Clara (Clustering Large Applications)

El algoritmo CLARA (*Clustering Large Applications*) está diseñado para ser eficiente cuando se trabaja con grandes volúmenes de datos, lo cual lo hace menos exigente en términos de recursos computacionales en comparación con otros métodos como *k-means* o PAM. La principal diferencia es que, en lugar de trabajar con todo el conjunto de datos, CLARA toma una muestra aleatoria del conjunto de datos y realiza el *clustering* solo sobre esa muestra. Esto permite que el algoritmo sea más rápido, ya que el proceso de *clustering* se ejecuta sobre un número reducido de puntos de datos. Una vez que CLARA ha realizado el clustering sobre la muestra, evalúa los resultados y selecciona el mejor agrupamiento teniendo en cuenta la cohesión interna de los *clusters* y la separación entre ellos. El número de muestras aleatorias tomadas para realizar el *clustering* es un parámetro clave que afecta el balance entre el tiempo de ejecución y la precisión del modelo. Si se usan pocas muestras, el algoritmo será más rápido, pero los resultados podrían no ser representativos de

la estructura global del conjunto de datos. Por el contrario, si se usan demasiadas muestras, el tiempo de ejecución puede aumentar significativamente, lo que hace que el proceso sea más costoso computacionalmente. En nuestro caso, hemos decidido usar cinco samples, una cantidad que consideramos razonable para obtener un buen equilibrio entre precisión y velocidad. Este número de muestras permite realizar un *clustering* eficiente sin que el proceso se vuelva excesivamente lento.




Figura 52: Visualización de los *clusters* con el método CLARA

A simple vista de la Figura 52, los *clusters* parecen bastante similares a los obtenidos anteriormente, lo que indica que la muestra utilizada ha representado bien la estructura general. Se sigue observando solapamiento entre los grupos, aunque la distribución de los puntos y la forma de las elipses sugieren que CLARA captura patrones similares a los otros métodos, pero con posibles diferencias en la asignación de ciertos puntos.

Las elipses siguen mostrando intersección entre los *clusters*, lo que indica que los datos pueden no estar bien separados en cuatro grupos claramente distintos. Sin embargo, al tratarse de una técnica diseñada para grandes conjuntos de datos, esto puede ser una limitación del modelo de *clustering* y no necesariamente del método.

5.2. Clustering jerárquicos

Así pues, empezamos con el *clustering* numérico, y más adelante procederemos con el mixto (que incluye las variables categóricas).

En dicho análisis, aplicamos diferentes métodos de *clustering* jerárquico con distancia euclídea para medir la proximidad entre observaciones. Se han utilizado siete métodos de agregación: *Single*, *Complete*, *Average*, *McQuitty*, *Median*, *Centroid* y *Ward.D2*, cada uno con una forma distinta de fusionar los grupos. *Single linkage* tiende a formar cadenas alargadas, mientras que *Complete* y *Average linkage* generan *clusters* más compactos. *Ward*, que minimiza la varianza dentro de los grupos,

suele ser una de las opciones más recomendadas. Se espera que los dendrogramas muestren estructuras diferentes según el método aplicado.

Para evaluar la calidad del *clustering*, hemos calculado la correlación cofenética, que mide la correspondencia entre la matriz de distancias original y la obtenida en el dendrograma. Una mayor correlación cofenética indica que la estructura del dendrograma refleja mejor las distancias originales entre los datos, lo que implica un *clustering* más representativo. El valor óptimo sería cercano a 1, lo que significaría una correspondencia perfecta entre el *clustering* y la matriz de distancias. Ahora en nuestro caso, los resultados muestran que *Single* (0.17) y *Median* (0.41) presentan valores significativamente bajos, por lo que los descartamos rápidamente. Entre los métodos restantes, *Average* (0.59) y *Centroid* (0.59) ofrecen el mejor ajuste, aunque las diferencias con *Ward* (0.58), *Complete* (0.57) y *McQuitty* (0.56) no son nada significativas. Esto sugiere que cualquiera de estos cinco últimos métodos puede ser una opción viable, dependiendo del criterio de agrupación que se prefiera.

Métricas	Correlaciones
Average	0.5934875
Centroid	0.5924009
Ward	0.5859970
Complete	0.5731776
McQuitty	0.5558066
Median	0.4069461
Single	0.1722219

Cuadro 10: Correlaciones de diferentes métricas de *clustering* numérico.

Métricas	Correlaciones
Average	0.4080307
Centroid	0.3865901
Single	0.3637295
Ward	0.3471350
Median	0.2608684
McQuitty	0.2583062
Complete	0.2542672

Cuadro 11: Correlaciones de diferentes métricas de *clustering* mixto.

Vamos ahora con el jerárquico mixto.

En este análisis, hemos incorporado variables categóricas al *clustering* mediante la distancia de Gower, que permite combinar datos de distinta naturaleza. Para garantizar que la matriz de disimilitud cumpla con las propiedades métricas, la hemos elevado al cuadrado antes de aplicar los métodos de *clustering* jerárquico. Se han utilizado los mismos algoritmos de agregación que en el análisis numérico: *Single*, *Complete*, *Average*, *McQuitty*, *Median*, *Centroid* y *Ward*. Ahora, podemos evaluar las diferencias en la estructura de los dendrogramas respecto al *clustering* numérico y analizar qué método ofrece una mejor representación de los datos mixtos.

Los dendrogramas de la Figura 53 muestran diferencias claras según el método de agregación empleado. *Single linkage* genera una estructura en forma de cadena, lo que indica que es muy sensible a *outliers*. *Complete*, *Average* y *McQuitty* presentan dendrogramas más equilibrados, con divisiones progresivas y grupos más definidos. *Median* y *Centroid* muestran cortes irregulares, lo que nos permite descartarlos como opción principal. *Ward*, como era de esperar, genera una estructura jerárquica bien equilibrada con *clusters* compactos, animándonos a elegirlo como candidato ideal.

Los valores de correlación cofenética son en general más bajos que en el *clustering* numérico, lo que indica una menor capacidad de los métodos para reflejar las distancias originales. *Average* (0.41) y *Centroid* (0.39) destacan como las mejores




Figura 53: Dendrogramas del *clustering* jerárquico mixto

opciones, aunque la calidad del ajuste es bastante limitada.

Utilizando la función *suggested_level*, el análisis de corte de los dendrogramas sugiere que 3 es el número óptimo de *clusters* en todos los casos, tanto en el *clustering* numérico como en el mixto. Esto indica una estructura consistente en los datos, lo que refuerza la estabilidad de la partición y sugiere que los patrones identificados en ambas metodologías son similares.

Métricas

Para comparar los distintos métodos de clustering, evaluamos varias métricas de calidad. El índice de Dunn mide la compactación y separación de los clusters, siendo mejores los valores altos. El coeficiente de silueta refleja la coherencia interna de los grupos, con valores cercanos a 1 indicando una mejor agrupación. El índice de Davies-Bouldin mide la dispersión interna y la separación entre clusters, donde valores bajos indican una mejor estructura. Finalmente, analizamos la separación y compactación de los clusters a través de la variabilidad interna y entre grupos, buscando minimizar la primera y maximizar la segunda.

Observamos que (Cuadro 12), con gran diferencia, el método de Ward es el que mejor optimiza estos valores. A continuación, presentamos una tabla con las tres mejores opciones tras comparar todos los métodos, destacando aquellas que ofrecen los mejores resultados.

El método *Ward* es el más adecuado para los datos numéricos, ya que optimiza las principales métricas de calidad del *clustering*. Presenta un coeficiente de silueta relativamente alto (0.2751), lo que indica una mejor coherencia interna en los *clusters*. Además, tiene una buena separación entre grupos (30.0483) y una baja compactación (1298190), lo que sugiere que los *clusters* están bien definidos y equilibrados. Finalmente, su índice CH (3359.47) es el más alto, lo que refuerza su

	Average_num	Centroid_num	Ward_num
Clusters	3	3	3
Tamaño Clusters	2760 - 3826 - 21	6605 - 1 - 1	2898 - 1627 - 2082
Dunn	0.03396668	0.11361331	0.03471051
Dunn2	1.395214	1.451989	1.305823
Silueta	0.2760431	0.2515640	0.2751385
Separación	31.03191	39.60306	30.04832
Compactación	1710034	2616523	1298190
WB Ratio	0.6763040	0.6568365	0.6081737
CH Index	1755.124478	2094.314	3359.471566

Cuadro 12: Comparación de métodos de *clustering*

eficacia en la segmentación. Cabe destacar que estos estadísticos no pueden aplicarse directamente en *clustering* jerárquico mixto, ya que muchos se basan en distancias euclidianas, inadecuadas para variables categóricas, y requieren nociones de compactación y dispersión que no se definen de la misma forma con distancias mixtas.




Figura 54: Dendrograma *Ward* con datos mixtos

Concluimos que tanto para el *clustering* jerárquico con las variables numéricas como con las todas las variables el *Ward linkage* es el más adecuado.

6. Profiling

Una vez aplicado los algoritmos del *clustering* debemos analizar los grupos obtenidos presentando sus características, es decir qué diferencia a cada grupo con los otros y qué tienen en común las observaciones de un mismo grupo. El profiling de los *clusters* se hará tanto con los *clusters* obtenidos con los particionales y con el *clustering* jerárquico. Como es de esperar, daremos más peso a aquellos *clusterings* que usan todas las variables de nuestro *Dataset*.

6.1. Clusters del k-means y PAM

El análisis del *clustering* realizado mediante el método de *k-means*, con un valor óptimo de *k* igual a 4, ha resultado en la identificación de cuatro grupos con las siguientes características. Se observa un equilibrio en el agrupamiento, dado que el tamaño de los grupos presenta una distribución homogénea: el primer grupo comprende 1670 observaciones, el segundo 1698, el tercero 1569 y el cuarto, 1670.

Las variables de mayor influencia en la definición de las agrupaciones son, en primer lugar, *Attendance*, donde se distingue que el primer y el tercer grupo presentan una mayor asistencia a clase en comparación con los restantes (Figura 55). En segundo lugar, se destaca la variable *Previous_Scores*, donde se evidencia que el primer y el cuarto grupo obtuvieron calificaciones previas significativamente superiores a las de los otros dos grupos (Figura 56).







Figura 55: *Boxplot* y diferencia media de *Attendance* (*kmeans* vs global)

Figura 56: *Boxplot* y diferencia de *Previous_Scores* (*kmeans* vs global)

Las variables categóricas no ejercen una influencia significativa en el agrupamiento mediante *k-means*. En consecuencia, las diferencias relativas observadas con respecto a la media del conjunto de datos completo no son sustanciales y no permiten extraer conclusiones definitivas sobre qué características, representadas en las variables categóricas, definen a los distintos grupos.

En consecuencia, considerando la influencia de las variables continuas previamente mencionadas, se observan las siguientes diferencias en la variable *Exam_Score* en relación con los repuestos (Figura 57). El Grupo 1, denominado **Estudiosos consistentes**, caracterizado por calificaciones previas más elevadas y un mayor número de horas de estudio, presenta una calificación promedio de 70.06, la más alta entre los distintos grupos.

Además, de los 11 estudiantes con una calificación final superior a 95, 10 pertenecen a este grupo. Le sigue el Grupo 3, denominado **Esforzados estratégicos**, que, aunque no muestra calificaciones previas tan altas, registra un número significativo de horas de estudio, alcanzando un promedio de 68.59 en la calificación final. El Grupo 4, denominado **Talentos relajados**, que no dedica tantas horas al estudio pero posee calificaciones previas elevadas, finaliza con un promedio de Exam Score de 65.79. Finalmente, el Grupo 2, denominado **Despreocupados**, con calificaciones previas bajas y escasas horas de estudio, obtiene las calificaciones de examen más bajas, con un promedio de 64.69.




Figura 57: *Boxplot* y diferencia media de *Exam_Score* (*cluster kmeans* vs global)

El agrupamiento efectuado mediante el método PAM presenta una distribución menos equitativa en comparación con el anterior, si bien también se identifican cuatro grupos. Se aprecia que el grupo 1 alberga 1942 observaciones, mientras que el grupo 2 contiene 1807, el grupo 3 comprende 1332, y finalmente, el grupo 4 incluye 1526 observaciones.

El método PAM agrupa de una manera en las que no se aprecian diferencias significativas entre las variables continuas. Todas ellas tienen distribuciones homogéneas para los distintos grupos. Por otro lado observamos algunas diferencias en las variables categóricas presentadas a continuación.




Figura 58: Diferencia en frecuencia relativa de *Parental_Involvement* (pam vs global)




Figura 59: Diferencia en frecuencia relativa de *Access_to_Resources* (pam vs global)

En el Grupo 4, se constata una mayor proporción de estudiantes cuyos padres muestran un alto nivel de involucramiento (Figura 58), en contraste con una menor proporción de aquellos con padres medianamente involucrados. En el Grupo 4 hay

una proporción de estudiantes más elevada con un acceso a recursos alto (Figura 59).

Respecto a las actividades extracurriculares, se ha observado que los estudiantes del grupo 3 muestran una marcada tendencia a no participar en ellas (Figura 60). Se registra un 20 % menos de participación en comparación con la media del total de estudiantes que sí realizan actividades extracurriculares.

En cuanto a la variable *Motivation_Level* se refiere, se observa que el grupo 3 tiene una proporción significativamente más alta que el resto de alumnos con un bajo nivel de motivación (Figura 61).





Figura 60: Diferencia en frecuencia relativa de *Extracurricular_Activities* (pam vs global) Figura 61: Diferencia en frecuencia relativa de *Motivation_Level* (pam vs global)

En los grupos elaborados por el método PAM, se observa que hay una proporción mas elevada de estudiantes con un ingreso familiar bajo en los Grupos 2 y 4 (Figura 62).

En el Grupo 3 se identifica una mayor proporción de estudiantes que perciben una alta calidad en el profesorado (Figura 63).





Figura 62: Diferencia en frecuencia relativa de *Family_Income* (pam vs global) Figura 63: Diferencia en frecuencia relativa de *Teacher_Quality* (pam vs global)

En cuanto a influencia de los compañeros, se concluye que el grupo 1 y el grupo 3 están formados por una proporción de alumnos con una influencia positiva de sus compañeros más alta (Figura 64).

En el grupo 3 se observa que tienen una proporción más alta de estudiantes que no viven cerca del colegio, sino a una distancia moderada (Figura 65).

En cuanto a la variables *Gender*, se concluye que el grupo 4 está compuesto por más mujeres que el resto. Tiene una proporción de mujeres más de un 20 % superior a la media (Figura 66).

En el grupo 2 se observa que los padres han ido más a la universidad que en el resto de grupos (Figura 67).




Figura 64: Diferencia en frecuencia relativa de *Peer_Influence* (pam vs global)




Figura 65: Diferencia en frecuencia relativa de *Distance_from_Home* (pam vs global)




Figura 66: Diferencia en frecuencia relativa de *Gender* (pam vs global)




Figura 67: Diferencia en frecuencia relativa de *Parental_Education* (pam vs global)

El análisis de los grupos revela diferencias en las características sociodemográficas y académicas de los estudiantes, aunque las variaciones en las puntuaciones de los exámenes no son estadísticamente significativas.

El Grupo 1, denominado **Estudiantes con respaldo social y económico**, presenta una media de Exam Score de 67.42. Se caracteriza por una mayor proporción de estudiantes provenientes de familias con ingresos más altos y que reciben una influencia positiva de sus compañeros.

El Grupo 2, identificado como **Estudiantes académicamente orientados**, tiene una media de 66.95 y está compuesto por alumnos cuyos padres han asistido en mayor medida a la universidad. Además, estos estudiantes son menos propensos a participar en actividades extraescolares.

El Grupo 3, denominado **Estudiantes con barreras externas**, registra la media más baja, con 66.34. Sus integrantes presentan niveles más bajos de motivación, provienen de familias con menores ingresos y viven a mayor distancia del colegio. No obstante, cuentan con una influencia positiva de sus compañeros y una mayor calidad en la enseñanza recibida.

Finalmente, el Grupo 4, identificado como **Estudiantes con alto apoyo familiar y recursos**, alcanza la media más alta, con 68.10. Este grupo está compuesto en mayor proporción por mujeres, cuenta con padres más involucrados en la educación de sus hijos y dispone de un mayor acceso a recursos educativos.

En conclusión, aunque existen diferencias en las puntuaciones promedio entre los grupos, estas no resultan significativas dentro de esta clasificación.




Figura 68: *Boxplot* y diferencia media de *Exam_Score* (pam vs global)

6.2. Clusters del jerárquico

El análisis de los datos nos permite identificar tres perfiles educativos claramente diferenciados entre los estudiantes. El primer cluster, que agrupa a estudiantes con apoyo familiar pero con necesidades educativas y bajo rendimiento, se caracteriza por una baja asistencia y peores resultados tanto en calificaciones previas como en el examen final, lo cual es coherente con su situación académica. Este perfil también

refleja la presencia de dificultades de aprendizaje y un entorno público con recursos medios, aunque con una implicación parental alta, lo que refuerza la idea de que, a pesar del apoyo familiar, estos estudiantes enfrentan limitaciones académicas relevantes. En contraste, en el segundo cluster, predominan estudiantes de alto rendimiento con autonomía y poco soporte familiar, presentando altas calificaciones y destaca por el efecto positivo de las tutorías y un buen desempeño en el examen, mostrando un perfil mucho más autónomo, sin dependencia de los padres, sin discapacidades y con mayor presencia femenina, donde la calidad docente es determinante y el soporte familiar resulta menos relevante. Suele estar alineado con la realidad, normalmente y generalizando mucho, las mujeres suelen sacar mejores notas ya que acostumbran a estudiar más en la mayoría de etapas del colegio que los hombres. Finalmente, en el último cluster, que hace referencia a estudiantes comprometidos pese a la desventaja económica y educativa, muestra un fuerte peso de la asistencia, lo que evidencia el compromiso de este grupo por mantenerse en el proceso educativo, a pesar de situaciones de baja motivación y recursos limitados.




Figura 69: Mapa de calor de las variables según *cluster*

La Figura 69 imagen amplía el análisis de los tres *clusters* mostrando cómo impactan distintas variables adicionales en cada grupo. En el Grupo 1 se refuerza el perfil de bajo rendimiento, con malas notas en el examen, poca asistencia y baja motivación, además de una fuerte influencia negativa de la distancia al centro educativo. El Grupo 2, por su parte, presenta un perfil más heterogéneo, donde variables como las tutorías y la motivación tienen un efecto positivo, mientras que la calidad docente parece influir negativamente en algunos casos. Por último, el Grupo 3 destaca por la influencia positiva de la asistencia y la implicación de los padres, lo que refuerza la idea de que este grupo obtiene buenos resultados gracias al apoyo familiar y la participación constante.

Respecto a la variable *Attendance*, tenemos que aunque en el *boxplot* de la Figura 70 las diferencias visuales entre los tres *clusters* parecen ínfimas (ya que las medianas y rangos son similares), el análisis más detallado y los resultados estadísticos confirman que la asistencia es una variable importante en la segmentación de los perfiles. La distribución de la variable en el histograma muestra cómo ciertos valores de asistencia se concentran más en el Grupo 3, que representa a los estudiantes comprometidos pese a la desventaja, mientras que en el Grupo 1 (bajo rendimiento) la frecuencia disminuye en los niveles más altos de asistencia.




Figura 70: Distribución de la asistencia según el cluster

Por otro lado, el análisis muestra variables como *Teacher_Quality* y *Motivation_Level* (Figuras 71 y 72) que no resultan significativas para diferenciar entre los tres *clusters*, ya que no muestran un peso relevante en ningún grupo. La ausencia de impacto de la calidad docente baja puede deberse a que su efecto queda diluido frente a otras variables más fuertes como el tipo de centro o los recursos. Por otro lado, la motivación alta tampoco marca diferencias claras, posiblemente porque el peso de la motivación en estos perfiles se suele manifestar en niveles medios-bajos, siendo la motivación alta poco representativa dentro de lo analizado. Esto refuerza la idea de que no todas las variables esperadas como importantes son realmente decisivas en la división de los estudiantes.




Figura 71: Frecuencia relativa de *Teacher_Quality* según *cluster*




Figura 72: Frecuencia relativa de *Motivation_Level* según *cluster*

Ambos gráficos muestran que no son variables determinantes en la segmentación, ya que los tres *clusters* se distribuyen de forma relativamente equilibrada en los niveles alto, medio y bajo, reforzando la conclusión de que tanto la motivación alta como la *low quality teacher* no diferencia de forma clara los perfiles de los estudiantes. Utilizamos la frecuencia relativa y no la absoluta ya que si no podríamos malinterpretar resultados.

Dicho esto, como conclusión tenemos que:

- El Grupo 1, **Estudiantes con apoyo familiar pero con necesidades educativas y bajo rendimiento**, agrupa a estudiantes con bajo rendimiento académico y dificultades de aprendizaje, que aunque cuentan con apoyo familiar y recursos medios, asisten poco a clase y se ven afectados por su entorno educativo.
- El Grupo 2, **Estudiantes de alto rendimiento con autonomía y poco soporte familiar** representa a los alumnos de mejor desempeño, autónomos y con escaso soporte familiar, que destacan por sus altas calificaciones, la ausencia de discapacidades y el acceso a una enseñanza de mayor calidad.
- Por último, el Grupo 3, **Estudiantes comprometidos pese a la desventaja económica y educativa** reúne a estudiantes comprometidos y constantes, que pese a enfrentarse a desventajas económicas y educativas, muestran una alta asistencia como reflejo de su esfuerzo por continuar en el sistema educativo.

6.3. Comparación de resultados

El estudio aplicado sobre datos educativos mediante técnicas de *clustering* ha permitido identificar perfiles diferenciados de estudiantes. Se utilizaron tres métodos: *k-means*, PAM y *clustering* jerárquico, cada uno con su propio enfoque y fortalezas. El objetivo fue entender cómo factores académicos y sociofamiliares influyen en el rendimiento de los alumnos, destacando qué variables definen a cada grupo y cuáles tienen más peso en el proceso educativo.

El método *k-means* generó cuatro *clusters* definidos sobre todo por variables numéricas, como la asistencia a clase, las calificaciones previas y las horas de estudio. Este análisis permitió distinguir perfiles académicos muy claros, como los **Estudiosos consistentes**, con buen historial y alta dedicación; los **Esforzados estratégicos**, que compensan con esfuerzo su menor preparación inicial; los **Talentos relajados**, que rinden aceptablemente sin estudiar mucho; y los **Despreocupados**, con bajo rendimiento y escaso compromiso. Las variables categóricas, como el contexto familiar o el género, no mostraron diferencias relevantes en esta segmentación.

Por su parte, el método PAM también generó cuatro grupos, pero destacó por capturar mejor los aspectos cualitativos y contextuales de los estudiantes. En este caso, las variables continuas no marcaron grandes diferencias entre grupos, pero sí lo hicieron características como el nivel de involucramiento parental, los ingresos familiares, la participación en actividades extracurriculares, la distancia al centro o el género. Aunque los promedios de nota final fueron parecidos entre los grupos, se pudieron identificar perfiles con fuerte apoyo familiar y recursos, estudiantes con barreras externas, alumnos con orientación académica por influencia de padres educados, y jóvenes con respaldo social y económico. La riqueza de esta clasificación radica más en el contexto de vida de los estudiantes que en su rendimiento medido por calificaciones.

El *clustering* jerárquico, que agrupó a los estudiantes en tres grandes perfiles, ofreció

la visión más completa e integrada al usar todas las variables del conjunto de datos. Permitió identificar a estudiantes con bajo rendimiento pese al apoyo familiar, a estudiantes de alto rendimiento con una actitud autónoma y poco soporte familiar, y a estudiantes comprometidos que, a pesar de enfrentar desventajas económicas y educativas, mantienen una alta asistencia como señal de esfuerzo. Esta segmentación puso en evidencia que el compromiso, la perseverancia y el contexto socioeducativo son tan relevantes como la motivación o el historial académico.

Comparando los tres métodos, se observa que cada uno aporta una perspectiva complementaria. *K-means* resalta la dimensión académica basada en datos cuantitativos, PAM destaca el entorno social y familiar, y el jerárquico sintetiza ambos enfoques, ofreciendo perfiles educativos más realistas y aplicables. Aunque los resultados de PAM no mostraron diferencias significativas en rendimiento, sí revelaron contextos personales muy distintos, útiles para intervenciones específicas. El análisis jerárquico, en cambio, sí logró diferenciar tanto el contexto como el rendimiento, y por ello sus perfiles resultan especialmente valiosos para comprender las distintas trayectorias educativas.

Grupo	Descripción	Número de alumnos
Grupo 1	Estudiantes con apoyo familiar pero con necesidades educativas y bajo rendimiento	1848
Grupo 2	Estudiantes de alto rendimiento con autonomía y poco soporte familiar	3236
Grupo 3	Estudiantes comprometidos pese a la desventaja económica y educativa	1523

Cuadro 13: *Profiling* definitivo de nuestro *Dataset*

En conjunto, el estudio refleja que no existe una única causa del rendimiento académico. Factores como la asistencia, la motivación, la calidad del profesorado, el apoyo familiar y los recursos disponibles interactúan entre sí de formas complejas. La combinación de métodos permitió enriquecer el análisis y evitar conclusiones simplistas. El resultado es una tipología de estudiantes diversa, útil para diseñar políticas educativas más justas y adaptadas a las realidades individuales.

7. ACP de las variables numéricas

Haciendo primero un breve recordatorio, como bien sabemos el Análisis de Componentes Principales (PCA) es una técnica de reducción de dimensionalidad que transforma un conjunto de variables numéricas correlacionadas en un nuevo conjunto de variables, llamadas componentes principales. Estos componentes se obtienen diagonalizando la matriz de correlaciones (o covarianzas) de los datos originales, lo que equivale a resolver la ecuación:

$$S \cdot v = \lambda v$$

donde S es la matriz de correlaciones, λ son los valores propios (que indican la varianza explicada por cada componente) y v son los vectores propios que definen las direcciones de las nuevas dimensiones. Los componentes se ordenan de mayor a menor λ , permitiendo conservar solo aquellos que capturan la mayor variabilidad.

La matriz de correlaciones surge de estandarizar los datos (si las escalas difieren) y calcular

$$S = \frac{1}{n-1} X^T \cdot X$$

donde X es la matriz con los datos centrados.




Figura 73: Matriz de correlaciones

En la Figura 73 podemos ver como, efectivamente presentamos anteriormente, está muy correlacionada la variable *Exam_Score* tanto con *Hours_Studied* (0.45) como con *Attendance* (0.58), mientras que el resto no aportan prácticamente nada.

Una vez ejecutado el análisis de componentes principales podemos concluir con la Figura 74 y la Tabla 14 que los primeros seis componentes explican el 96,8 % de la varianza. Comp.1 (25,2 %) refleja rendimiento académico (*Exam_Score*, *Attendance*), mientras que Comp.2 (15 %) contrasta horas de estudio con tutorías. Por otro lado, Comp.3 (14,6 %) vincula actividad física y sueño.




Figura 74: *Scree plot* del PCA

Dimensión	Eigenvalue	Varianza (%)	Varianza acumulada (%)
Dim.1	1.7650438	25.214912	25.21491
Dim.2	1.0498208	14.997440	40.21235
Dim.3	1.0217778	14.596826	54.80918
Dim.4	1.0167387	14.524839	69.33402
Dim.5	0.9706703	13.866719	83.20074
Dim.6	0.9506016	13.580023	96.78076
Dim.7	0.2253469	3.219241	100.00000

Cuadro 14: Variabilidad por componentes principales del PCA

En primer lugar, los eigenvalues de los componentes (Dim.1 a Dim.7) oscilan entre 1.77 (Dim.1) y 0.22 (Dim.7), donde solo los primeros cuatro superan el umbral de Kaiser (eigenvalue ≥ 1), justificando retener hasta la Dim.4 (69.3 % de varianza acumulada). Sin embargo, la varianza explicada individual decrece gradualmente: Dim.1 (25.2 %), Dim.2 (15 %), Dim.3 (14.6 %), Dim.4 (14.5 %), lo que complica identificar un punto de corte claro. Aunque el método del codo sugiere 6 componentes (al capturar el 96.8 % de varianza), y el criterio del porcentaje (>80 %) recomendaría

5 componentes, ninguno coincide con el límite de *Kaiser*, creándose ciertas dudas acerca de cuál elegir.

La discrepancia entre métodos (4, 5 o 6 componentes) refleja que la estructura latente no está dominada por pocas dimensiones, sino distribuida en múltiples factores. Esto exige un análisis gráfico complementario y validación teórica para priorizar componentes.




Figura 75: Proyección de las variables numéricas sobre el plano de las dos primeras componentes principales

Dim 1 vs Dim 2

En este primer gráfico de la Figura 75^{§§} *Exam_Score* domina claramente en la Dimensión 1, con una contribución superior al 30 %, lo que indica su fuerte influencia en esta dimensión.

Physical_Activity y *Sleep_Hours* tienen mayor carga sobre la Dimensión 2, apuntando a un eje relacionado con hábitos saludables. *Hours_Studied*, *Attendance* y *Previous_Hours* también contribuyen significativamente a la Dimensión 1, reforzando su interpretación como eje del rendimiento académico. *Tutoring_Sessions* aparece en una posición intermedia, sin una carga clara en ninguna de las dos dimensiones principales.

Esta combinación sugiere que Dim 1 representa el compromiso y desempeño académico, mientras que Dim 2 recoge aspectos del estilo de vida y bienestar del alumno.

^{§§}Los demás gráficos para los párrafos que vienen se presentan en el RMD.

Dim 1 vs Dim 3

Exam_Score sigue liderando la Dimensión 1. *Physical_Activity* domina en Dim 3, apuntando a hábitos de autocuidado. *Sleep_Hours*, *Tutoring_Sessions* y *Previous_Hours* también destacan en Dim 3. Dim 3 parece reflejar bienestar personal y apoyo académico externo.

Dim 1 vs Dim 4

Exam_Score mantiene su peso central en Dim 1. *Sleep_Hours* se proyecta en sentido opuesto en Dim 4, indicando contraste con la exigencia académica. *Hours_Studied* y *Attendance* se distribuyen entre ambas dimensiones. Dim 4 sugiere un eje de balance entre descanso y compromiso académico.

Dim 1 vs Dim 5

Tutoring_Sessions lidera en Dim 5, opuesta a *Physical_Activity*. *Exam_Score* continúa como referencia clave en Dim 1. Dim 5 podría representar la dicotomía entre apoyo externo y hábitos personales.

Dim 1 vs Dim 6

Exam_Score, *Attendance* y *Hours_Studied* siguen marcando la Dim 1. Dim 6 agrupa variables como *Sleep_Hours*, *Physical_Activity* y *Previous_Hours*, ligadas a rutina o estabilidad. *Tutoring_Sessions* muestra una posición particular, añadiendo matices.

Dim 1 vs Dim 7

Exam_Score conserva su influencia en Dim 1. Dim 7 explica poca varianza (3.2 %) y carece de patrón definido. Las variables se agrupan cerca del origen, sin direcciones claras. Parece ser una dimensión residual, con escaso valor interpretativo.

Comentario general

A la vista de los resultados obtenidos en los distintos planos factoriales, observamos que la primera dimensión está claramente asociada al rendimiento académico, ya que agrupa variables como *Exam_Score*, *Hours_Studied*, *Attendance* y *Previous_Hours*. Las dimensiones siguientes capturan diferentes aspectos del estilo de vida del alumno, como *Physical_Activity*, *Sleep_Hours* y *Tutoring_Sessions*, aunque su varianza explicada individualmente es menor. Por tanto, optamos por reducir la interpretación a dos dimensiones principales: una primera centrada en el **desempeño académico** y una segunda que sintetiza los componentes restantes y representa un eje de *estilo de vida* o *bienestar personal*. Esta simplificación es coherente con los objetivos del análisis y permite una lectura más clara y estructurada de los factores que influyen en el perfil del estudiante.

8. ACM de las variables cualitativas

El análisis de correspondencias múltiples se ha llevado a cabo mediante el primer archivo *csv* generado por el algoritmo *Mice* en la primera parte del documento.

Cabe recalcar también que, gracias al estudio realizado en la descriptiva bivariante entre variables categóricas, hemos podido observar qué pares de variables sugieren una asociación entre ellas. Por lo que a partir de ahora el análisis de correspondencias múltiple se llevará a cabo con las siguientes variables: *Parental_Involvement*, *Access_to_Resources*, *School_Type*, *Extracurricular_Activities*, *Peer_Influence*, *Motivation_Level* y *Teacher_Quality*.

El siguiente paso de este apartado ha sido poder observar qué variables categóricas tenían muy baja frecuencia en alguna de sus categorías, ya que este tipo de atributos pueden distorsionar el análisis y deben ser eliminadas. Observando el siguiente histograma de la Figura 76 –y realizando las tablas de frecuencia para las variables– se ha podido observar que se tiene una variable con baja frecuencia en alguna de sus categorías:

Aún así, este porcentaje en la categoría *Low* supera el 10 %, por lo que consideramos que no se eliminará esta variable ya que el peso de la categoría no es, ni mucho menos, residual.

A continuación, ya con el *Dataset* filtrado con las variables que pasaron el Test de Independencia, nos interesa ver entre qué categorías de una misma variable o entre variables hay asociación.

Por tanto, el objetivo a partir de ahora es llevar a cabo una reducción de la dimensionalidad de la base de datos. Es necesario informar

que trabajaremos con una Tabla Lógica o Indicadora, la cual es una matriz binaria donde cada fila representa un individuo o un caso, mientras que cada columna representa una categoría posible de todas las variables cualitativas. Es necesario afirmar que, a diferencia del PCA (Análisis de Componentes Principales), en el ACM la inercia total está repartida de manera mucho más uniforme entre las dimensiones, y esto es debido a que las variables son categóricas y la inercia depende de la cantidad de variables y categorías. Por ende, el porcentaje explicado por cada dimensión suele ser pequeño y parecido entre ellas. La inercia máxima se acumula en $k - p = 19 - 7 = 12$ dimensiones aunque en el *screeplot* siguiente de la Figura 77 solo se muestran las primeras 10.

Como es fácil observar, cada dimensión retiene un porcentaje parecido de la inercia total. Aún así, en estar trabajando con una Tabla Indicadora y no con una




Figura 76: Histograma de la variable *Teacher_Quality*




Figura 77: *Screeplot* del ACM

Tabla de Burt,^{¶¶} será necesario elegir las dimensiones que nos quedamos mediante los valores propios siguiendo los siguientes pasos:

1. Nos quedamos con las dimensiones dónde $\lambda > \frac{1}{p}$, siendo p el número de variables con las que estamos trabajando.
2. Con el siguiente comando de RStudio, podemos comprobar como el número de dimensiones con las que tenemos que trabajar son seis: `sum(eig.val[, 'eigenvalue'] > 1/7) // which(eig.val[, 'eigenvalue'] > 1/7)`

A modo de observación, puede ser importante destacar que las seis primeras dimensiones captan un 52 % de la inercia total, véase en la siguiente Tabla 15.

Dimensión	Eigenvalue	Varianza (%)	Varianza acumulada (%)
Dim.1	0.1536370	8.962161	8.962161
Dim.2	0.1522435	8.880870	17.843031
Dim.3	0.1477577	8.619202	26.462233
Dim.4	0.1476692	8.614039	35.076271
Dim.5	0.1455503	8.490434	43.566705
Dim.6	0.1442022	8.411797	51.978502
Dim.7	0.1415274	8.255767	60.234269
Dim.8	0.1403291	8.185864	68.420132
Dim.9	0.1385961	8.084770	76.504902
Dim.10	0.1364018	7.956772	84.461675
Dim.11	0.1355693	7.908212	92.369887
Dim.12	0.1308019	7.630113	100.000000

Cuadro 15: Resumen de valores propios y varianza explicada por dimensión

^{¶¶}Con la Tabla de Burt, es necesario elegir el número de dimensiones mediante el método del codo o mirando las dimensiones que acumulan un 75 % o más de la inercia.

Por tanto, se concluye que, mediante el ACM de las variables que habían pasado el Test de Independencia de χ^2 (los pares de variables dependientes entre ellos), es necesario trabajar con al menos 6 dimensiones, criterio fijado mediante los autovaleores.

Seguidamente, se expone en la Figura 78 un gráfico que sirve para visualizar cuánto contribuye cada variable con cada dimensión del gráfico: respecto al eje OY , cómo más hacia el eje positivo esté la variable, más contribuye con la dimensión, e ídem para el eje OX .




Figura 78: Plano factorial de las variables en las primeras dos dimensiones

Como se puede observar en el gráfico anterior, respecto a la dimensión 1, las variables que contribuyen más a definir esta dimensión son *Motivation_Level*, *Parental_Involvement* y *Teacher_Quality*. En cuanto a la dimensión 2, la variable que más contribuye es *Peer_Influence*, seguida de *Extracurricular_Activities*.

Aún así, nos interesa ver qué modalidades o categorías son parecidas u opuestas entre ellas, y cuánto aportan a cada dimensión. Debido a esto, y mediante el siguiente código que se adjunta, se genera el gráfico de la Figura 79 que muestra el plano factorial de todas las modalidades de cada variable y se extraerán las conclusiones pertinentes para el análisis, `fviz_mca_var(res.mca, repel = TRUE, ggtheme = theme_minimal())`.

De manera inicial, lo primero que se puede observar es que las categorías que contribuyen más a la dimensión 1 son *Teacher_Quality_Low* y *Parental_Involvement_Low*, mientras que las que contribuyen más a la dimensión 2 son *Teacher_Quality_Low*, *Motivation_Level_High*, *Negative* y *Neutral*.

Se recalca también que, aunque cada dimensión explica una cantidad baja de la variabilidad total (síntoma común en el ACM), las categorías alejadas del origen son importantes en su contribución a la dimensión, y además se pueden sacar conclusiones precisas en cuánto a la distancia entre cada categoría de cada variable.




Figura 79: Plano factorial de todas las modalidades de cada variables respecto a las dos primeras dimensiones

Del gráfico anterior, se pueden observar varios comportamientos interesantes, como por ejemplo que *Teacher_Quality_Low*, al estar tan alejado del centro, contribuye de manera fuerte a la primera y la segunda dimensión y está muy diferenciada del resto de categorías, por lo tanto es una categoría que está presente en combinaciones poco frecuentes o muy extremas de las variables, generando una gran inercia. Es necesario explicar también que en la zona inferior derecha observamos las categorías *Parental_Involvement_Low* y *Motivation_Level_High*, que están bastante alejadas del punto (0,0), y puede indicar perfiles de alumnado o contextos con implicación baja de los padres pero motivación alta del alumno. Estas dos categorías son antagónicas de tipos de escuelas privadas o de influencia del entorno neutral (se sitúan en cuadrantes diferentes y opuestos). En la zona central del plano factorial se sitúan categorías como *Parental_Involvement_Medium*, *Public*, *Motivation_Level_Low*, etc. Estas contribuyen poco a la diferenciación de las dimensiones principales y están más balanceadas entre sí, e indican que tienen características similares: el tipo de escuela pública está muy relacionado con el acceso a recursos medio, o el acceso a recursos bajo está muy relacionado con una calidad alta del profesor (Los alumnos cuyos padres hacen esfuerzos para poder pagar la escuela tienden a valorar más los profesores que tienen). Finalmente, una última conclusión puede ser observar que los alumnos con una influencia del entorno negativa son completamente opuestos a esos que atienden las clases en un tipo de escuela privada. Estos que van a escuela privada, aunque no tengan un alto nivel de motivación, tampoco valoran la calidad del profesorado como baja, lo que hace indicar que ni los mejores profesores ni un involucramiento parental alto son necesarios para motivar a alumnos de universidades privadas.

A continuación se muestra el mismo gráfico (Figura 80) que el anterior, pero añadiendo los individuos en un color grisáceo para observar en qué categorías hay más casos; se recalca que las conclusiones son las mismas que anteriormente.




Figura 80: Plano factorial de los individuos sobre las primeras dos dimensiones

Finalmente, y a modo de observación, lo que se hace es observar la calidad de la representación de las categorías de las variables con los siguientes tres gráficos (Figura 81).




Figura 81: Gráficos que representan la calidad de nuestro ACM

En conclusión, lo que muestran estos gráficos es que *Access_to_Resources_High*, *Parental_Involvement_Medium*, *Teacher_Quality_High*, *Teacher_Quality_Medium* y *Positive* no están muy bien representadas por las dos primeras dimensiones: esto implica que la posición de los centros de gravedad en el *scatterplot* tienen que ser interpretadas con cuidado, con el riesgo que eso conlleva. También muestran que las categorías *Teacher_Quality_Low*, *Parental_Involvement_Low*, *Motivation_Level_Low*, por ejemplo, se ven bien representadas por la dimensión 1 y la dimensión 2. Evidentemente, en nuestro análisis se ha podido observar que, con el uso de una Tabla Lógica, las dimensiones con las que teníamos que trabajar eran seis, por lo que habrá categorías que no puedan verse reflejadas correctamente con las dos primeras de manera gráfica. Para concluir el estudio, se realiza una descripción de las dimensiones 1 y 2 por separado para observar la relación entre la variable y las categorías de las variables categóricas mediante el siguiente comando: `res.desc <- dimdesc(res.mca, axes = c(1,2)) // res.desc // res.desc[[1]] // res.desc[[2]]`.

Variable	Dimensión 1		Dimensión 2	
	Estimate	p-value	Estimate	p-value
Peer_Influence = Neutral	0.2961	0.00	0.2961	0.00
Extracurricular_Activities = No	-0.1971	0.00	-0.1971	0.00
School_Type = Private	0.1412	2.34e-18	0.1412	2.34e-18
Motivation_Level = Medium	0.1842	4.54e-155	0.1842	2.45e-155
Teacher_Quality = Low	0.2258	1.87e-113	0.2258	1.87e-113
Parental_Involvement = High	0.1886	5.25e-110	0.1886	5.25e-110
Access_to_Resources = High	0.0432	5.53e-20	0.0432	5.53e-20
Access_to_Resources = Low	0.0512	4.81e-08	0.0512	4.81e-08
Motivation_Level = Low	0.0420	1.58e-02	0.0420	1.58e-02
Teacher_Quality = High	0.0679	8.36e-04	0.0679	8.36e-04
Access_to_Resources = Medium	-0.0963	2.73e-51	-0.0963	2.73e-51
Teacher_Quality = Medium	-0.1578	7.91e-84	-0.1578	7.91e-84
Peer_Influence = Positive	-0.0645	1.68e-75	-0.0645	1.68e-75
Parental_Involvement = Low	-0.2189	1.16e-12	-0.2189	1.16e-12
School_Type = Public	-0.1416	2.34e-18	-0.1416	2.34e-18
Peer_Influence = Negative	-0.2312	2.35e-21	-0.2246	2.35e-21
Motivation_Level = High	-0.2246	4.53e-28	-0.2246	4.53e-28
Extracurricular_Activities = Yes	-0.1971	0.00	-0.1971	0.00

Cuadro 16: Coeficientes estimados y p-valores para las Dimensiones 1 y 2

La Tabla 16 anterior sirve únicamente para poder comprobar lo que se venía explicando en el estudio y las contribuciones de cada categoría para cada dimensión. La columna de estimates sirve para ver el signo y el grado de contribución a la dimensión, con su p-valor asociado: si el signo es positivo, está en el lado positivo de la dimensión, mientras que si es negativo, está en el lado negativo de la misma. Simplemente es el estudio desglosado para cada dimensión de lo que se había estudiado en los tres gráficos anteriores para las dos dimensiones conjuntamente.

A continuación realizaremos resumidamente el mismo análisis comparando otras dimensiones.***

Dim 3 vs Dim 4

Observando el gráfico de las categorías para la Dimensión 3 contra la Dimensión 4, se pueden destacar varias agrupaciones y oposiciones. En el cuadrante superior derecho, categorías como *Access.to.Resources.High* y *Negative (Peer.Influence)* muestran una asociación, sugiriendo que un alto acceso a recursos podría estar relacionado con una influencia negativa de los compañeros en este plano dimensional. Opuesto a estas, en el cuadrante inferior izquierdo, se encuentra *Neutral (Peer.Influence)* y *Teacher.Quality.Low*, indicando una posible relación entre una influencia neutral de compañeros y una baja calidad percibida del profesorado. La categoría *Private (School.Type)* se sitúa aislada en el lado derecho, mientras que *Public (School.Type)* está en el cuadrante inferior izquierdo, cerca de *Access.to.Resources.Medium*. Las categorías *Motivation.Level.High* y *Teacher.Quality.High* se localizan en el cuadrante inferior derecho, diferenciándose claramente de *Parental.Involvement.High* y *Teacher.Quality.Medium* en el cuadrante superior izquierdo.

En el plano definido por las Dimensiones 3 y 4, se observa una posible asociación paradójica entre un alto acceso a recursos y una influencia negativa de los compañeros, destacando patrones complejos en el entorno educativo de los estudiantes.

Dim 4 vs Dim 5

El análisis del plano factorial entre la Dimensión 4 y la Dimensión 5 revela que *Teacher.Quality.Low* y *Positive (Peer.Influence)* se encuentran en la parte superior, indicando una posible relación entre ellas en este espacio bidimensional. En oposición, en la parte inferior, se agrupan categorías como *Neutral (Peer.Influence)*, *Motivation.Level.Low* y *Negative (Peer.Influence)*, sugiriendo un perfil donde la neutralidad o negatividad en la influencia de pares se asocia con baja motivación. *Access.to.Resources.Low* se proyecta en el cuadrante superior izquierdo, mientras que *Access.to.Resources.High* lo hace en el derecho, cercano al eje horizontal. Las categorías *Parental.Involvement.High* se sitúa en el cuadrante superior derecho, y *Parental.Involvement.Low* en el centro-derecha, cerca de *Teacher.Quality.Medium*. *Motivation.Level.High* se encuentra en el cuadrante inferior izquierdo, opuesto a *Motivation.Level.Medium* en el centro-derecha.

El cruce entre las Dimensiones 4 y 5 revela que la baja calidad del profesorado se asocia con una influencia positiva de los compañeros, mientras que una motivación baja tiende a coincidir con influencias negativas o neutras del entorno social.

Dim 1 vs Dim 3

Al examinar el gráfico de la Dimensión 1 contra la Dimensión 3, observamos que *Access.to.Resources.High* y *Teacher.Quality.Low* se posicionan en el extremo

***Los gráficos, necesarios para esta última parte, que comparan otros pares de dimensiones tal y como la Figura 78 o 79 se pueden consultar en el RMD.

superior derecho, indicando una fuerte contribución y posible coocurrencia en perfiles específicos. En contraposición, en el cuadrante inferior izquierdo, se agrupan *Motivation_Level_Low*, *Parental_Involvement_High* y *Teacher_Quality_Medium*. Esto podría sugerir que una baja motivación y alta implicación parental se asocian con una calidad media del profesorado en este plano. La categoría *Private (School_Type)* se encuentra en el cuadrante superior izquierdo, mientras que *Public (School_Type)* se sitúa en el inferior derecho, cerca de *Motivation_Level_Medium*. Las categorías *Parental_Involvement_Low* y *Teacher_Quality_Low* muestran una cercanía en el lado derecho del gráfico.

En el plano entre las Dimensiones 1 y 3, se destaca la coocurrencia entre alto acceso a recursos y baja calidad docente, frente a un perfil de baja motivación con alta implicación parental y calidad docente media.

Dim 1 vs Dim 5

El gráfico que cruza la Dimensión 1 con la Dimensión 5 muestra a *Positive (Peer_Influence)* y *Teacher_Quality_Low* en la parte superior derecha, sugiriendo que una baja calidad del profesorado podría estar relacionada con una influencia positiva de los compañeros. En el extremo opuesto, en la zona inferior izquierda, se localizan *Negative (Peer_Influence)* y *Motivation_Level_Low*, indicando una posible asociación entre una influencia negativa del entorno y una baja motivación. *Parental_Involvement_High* y *Access_to_Resources_Low* están en el cuadrante superior izquierdo. Mientras tanto, *Parental_Involvement_Low* se sitúa en el cuadrante inferior derecho, próximo a *Access_to_Resources_Medium*. Las categorías *Motivation_Level_High* y *Teacher_Quality_High* están cerca del centro, en el cuadrante inferior izquierdo.

El análisis entre las Dimensiones 1 y 5 sugiere que una influencia positiva de los compañeros podría coexistir con una baja calidad del profesorado, en contraste con entornos más negativos donde la motivación estudiantil es también baja.

Dim 2 vs Dim 4

Analizando la Dimensión 2 frente a la Dimensión 4, se observa que *Negative (Peer_Influence)* y *Access_to_Resources_High* se encuentran en el cuadrante superior derecho. Esto podría interpretarse como una asociación entre tener altos recursos y una influencia negativa de los compañeros. Por otro lado, *Motivation_Level_High* se sitúa en el extremo inferior izquierdo, muy alejado del resto, lo que indica una fuerte diferenciación de esta categoría en este plano factorial. Las categorías *Private* y *Parental_Involvement_High* están en el cuadrante superior derecho, mientras que *Teacher_Quality_Low* y *Neutral (Peer_Influence)* están en el inferior derecho. En el cuadrante superior izquierdo, *Parental_Involvement_Low* y *Teacher_Quality_Medium* muestran proximidad.

La Dimensión 2 contra la 4 muestra una fuerte diferenciación de la alta motivación estudiantil respecto al resto del mapa, mientras que un acceso alto a recursos vuelve a asociarse con influencias sociales negativas.

Dim 2 vs Dim 5

En el plano factorial definido por la Dimensión 2 y la Dimensión 5, la categoría *Positive (Peer_Influence)* y *Teacher_Quality_Low* se ubican en la parte superior derecha, sugiriendo una posible relación. *Parental_Involvement_High* también se encuentra en esta zona. En oposición, en el cuadrante inferior izquierdo, se sitúan *Negative (Peer_Influence)* y *Motivation_Level_Low*, indicando perfiles donde una influencia negativa del entorno se asocia con baja motivación. *Access_to_Resources_Low* está en el cuadrante superior central. Las categorías *Neutral (Peer_Influence)* y *No (Extracurricular_Activities)* se encuentran en el cuadrante inferior derecho, mientras que *Motivation_Level_High* está en el inferior izquierdo, cerca de *Parental_Involvement_Low*.

En el plano factorial entre las Dimensiones 2 y 5, se refuerza la idea de una relación entre influencia positiva de compañeros y baja calidad docente, frente a perfiles de baja motivación vinculados a una influencia negativa del entorno.

Dim 3 vs Dim 5

Finalmente, al observar la Dimensión 3 contra la Dimensión 5, vemos que *Teacher_Quality_Low* y *Positive (Peer_Influence)* están en el cuadrante superior izquierdo, mientras que *Access_to_Resources_High* y *Yes (Extracurricular_Activities)* están en el cuadrante derecho, hacia el centro. En el extremo inferior derecho se encuentra *Negative (Peer_Influence)*, opuesta a *Positive*. Las categorías *Parental_Involvement_High* se sitúa en el cuadrante superior izquierdo. *Motivation_Level_High* y *Teacher_Quality_High* se localizan en el cuadrante inferior derecho, cerca de *Parental_Involvement_Medium* y *Private*. *Neutral (Peer_Influence)* está en el cuadrante inferior central-derecho, y *Access_to_Resources_Medium* en el inferior izquierdo.

El cruce entre las Dimensiones 3 y 5 revela una clara oposición entre influencias positivas y negativas de los compañeros, con perfiles motivados y recursos altos contrastando con entornos más desfavorables.

9. Análisis factorial de datos mixtos (FAMD)

El análisis factorial de datos mixtos, al igual que el ACM, se ha llevado a cabo mediante el primer archivo *csv* generado por el algoritmo *Mice* presentado al inicio del trabajo.

Dado que nuestra base de datos contiene tanto variables cuantitativas como cualitativas, hemos aplicado el Análisis Factorial de Datos Mixtos (FAMD). El objetivo principal es reducir la dimensionalidad del conjunto de datos, permitiéndonos detectar asociaciones entre las categorías de las variables y comprender mejor los patrones subyacentes. Esta metodología permite representar simultáneamente a los individuos y las modalidades de las variables en un mismo espacio factorial, lo que facilita la identificación de relaciones de proximidad, similitud o contraste entre ellos.




Figura 82: *Scree plot* del FAMD

Como podemos ver en el *screeplot* de la Figura 82, no se aprecia ningún codo, por lo que no podremos realizar una reducción de dimensiones. Esto es probablemente debido a que nuestra base de datos es artificial y no proviene de datos reales. Para poder seguir con el estudio del FAMD, hemos contrastado las dimensiones 1 y 2, ya que son las que explican mayor varianza, aunque ésta sea muy baja (un 4.8 % y un 4.7 % respectivamente).

En el gráfico de individuos de la Figura 83 podemos ver cómo la calidad de representación es muy baja, con prácticamente solo los bordes coloreados, por lo que volveremos a realizar el estudio usando solo las variables cuantitativas que hemos observado que contribuyen más a las dimensiones 1,2 y 3 en el PCA. Respecto a las variables cualitativas, cómo hemos podido observar en el MCA, el *screeplot* tampoco tiene un codo definido, por lo que no podemos reducir las variables que tendremos que usar para nuestro FAMD. En conclusión, el Análisis Factorial de Datos Mixtos (FAMD) aplicado a este conjunto de datos artificial reveló limitaciones significativas. La baja varianza explicada por las primeras dimensiones (aproximadamente 4.8 %

para la Dimensión 1 y 4.7% para la Dimensión 2) y la ausencia de un codo claro en el gráfico de sedimentación dificultaron la reducción de dimensionalidad. La calidad de representación de individuos y variables cuantitativas como *Hours_Studied* y *Attendance* fue baja, lo que exige cautela al interpretar los primeros ejes.

A pesar de estas dificultades, observamos con la Figura 84 que el análisis de categorías cualitativas identificó algunas asociaciones y oposiciones en el primer plano factorial (Dim 1 vs Dim 2), como la agrupación de *Parental_Involvement_Low* y *Family_Income_Low*, y la contribución de *Teacher_Quality_Low* y *Access_to_Resources_High* a la Dimensión 1. Sin embargo, la proximidad de muchas categorías al origen sugiere que las dos primeras dimensiones no discriminan eficazmente entre ellas.




Figura 83: Mapa factorial de individuos




Figura 84: Representación de calidad

En resumen, si bien el FAMD es adecuado para datos mixtos, su efectividad en este caso se vio limitada por las características del dataset artificial. La escasa varianza explicada indica patrones débiles o distribuidos en más dimensiones, o una complejidad que los métodos factoriales lineales no capturan fácilmente en este conjunto de datos específico. La naturaleza artificial de los datos es un factor crítico para la interpretación de estos resultados.

10. Clustering jerárquico sobre componentes factoriales

El clustering FAMD consiste en utilizar las coordenadas de las componentes retenidas en el análisis factorial de datos mixtos, en el que se combinan variables categóricas y numéricas, con el objetivo de agrupar las coordenadas en k grupos o *clusters*, asignando cada coordenada a un solo *cluster*.

La matriz que utilizamos como entrada al proceso de clustering es la matriz de coordenadas individuales obtenida tras aplicar el FAMD. Esta matriz contiene las coordenadas de cada individuo en el nuevo espacio reducido, considerando solo las 19 primeras dimensiones, que explican aproximadamente más del 80 % de la variabilidad de los datos originales.

Dimensión	Eigenvalue	Varianza %	Varianza acumulada %
Dim.1	1.1108620	4.829835	4.829835
Dim.2	1.0913551	4.745022	9.574857
Dim.3	1.0801597	4.700620	14.275116
Dim.4	1.0602673	4.635664	18.910781
Dim.5	1.0508201	4.602818	23.513598
Dim.6	1.0481182	4.557021	28.070619
Dim.7	1.0253792	4.466779	32.537398
Dim.8	1.0213368	4.457124	36.994523
Dim.9	0.9832951	4.292951	41.287474
Dim.10	0.9576141	4.322661	45.610135
Dim.11	0.9437549	4.165687	49.775822
Dim.12	0.9324191	4.316384	54.092206
Dim.13	0.9908408	4.306891	58.399096
Dim.14	0.9862448	4.284999	62.684095
Dim.15	0.9741189	4.233509	66.917604
Dim.16	0.9708471	4.223726	71.141329
Dim.17	0.9594575	4.176424	75.317753
Dim.18	0.9459926	4.113922	79.431675
Dim.19	0.9415249	4.095761	83.527436
Dim.20	0.9344818	4.025702	87.553138
Dim.21	0.9213424	4.017795	91.570933
Dim.22	0.9161165	4.029186	95.600120
Dim.23	0.9006365	3.915811	100.000000

Cuadro 17: Resumen de los valores propios y varianza explicada por cada dimensión

Esta transformación a coordenadas nos permite trabajar con una representación numérica de todas las variables inicialmente mixtas, de forma estandarizada y sin redundancia.

10.1. Clustering particional

Una vez tenemos la matriz decidimos hacer un clustering particional, ya que al utilizar coordenadas y al ser todas numéricas es ideal para hacer *k-means*, que asume tener distancias euclidianas como medida de proximidad entre individuos y no hay necesidad de estandarizar nuevamente. También usaremos los métodos PAM y CLARA para nuestro análisis.

10.1.1. Selección del *k*-óptimo

Igual que hicimos con los datos sin utilizar métodos de reducción, para determinar el valor *k*-óptimo, es decir, el número de clusters óptimo, usaremos los siguientes métodos.

Elbow method

Como se puede ver en la Figura 85 cada vez que agregamos un nuevo *cluster*, la inercia baja más o menos lo mismo, por lo tanto, no hay un codo claro, porque no hay un punto donde la pendiente cambie bruscamente.

Esto nos hace ver que el método del codo no es concluyente y que debemos observar otros métodos.




Figura 85: Varianza total en función del número de *clusters*

Gap statistic

Para este método explicado anteriormente, elegiremos como *k* aquel que maximiza la diferencia entre las *SSE* observadas y las *SSE* esperadas.

Como se puede analizar en el gráfico de la Figura 86 no hay un momento en el que se estabilice el crecimiento, podría haberlo pero sería un valor de *k* muy elevado, por lo tanto nos decantamos por utilizar otro método.

Silhouette method

Para este método, en el que medimos la similitud de cada objeto en su propio grupo en comparación con los otros, tal y como se ve en este plot el número ideal de *clusters* es 2, ya que es el número en el que tenemos un valor máximo en el índice de la silueta. Por lo tanto, en el momento de hacer *k-means*, PAM y CLARA, el número óptimo de *clusters* será 2.




Figura 86: El GAP estadístico en función del número de *clusters*




Figura 87: *Silhouette* media en función del número de *clusters*

10.1.2. Aplicación de diferentes métodos particionales

Una vez determinado el número de clusters k -óptimo, realizamos el agrupamiento de los datos. Como hemos dicho antes usaremos k -means, PAM y CLARA. Cada *cluster* está definido por sus características propias y cada coordenada pertenece a un *cluster*.

k-Means

Como hemos dicho anteriormente el método k -means es un algoritmo no supervisado que se utiliza para resolver problemas de *clustering*. Su objetivo principal es dividir un conjunto de datos en k grupos, en nuestro caso $k = 2$, donde cada grupo contiene elementos similares entre sí, según alguna métrica, en nuestro caso la distancia euclidiana. Para este algoritmo se utiliza la media de los centroides de cada grupo.




Figura 88: Proyección del k -means

En nuestro caso, la representación visual sobre las primeras dos dimensiones del FAMD (Figura 88) no muestra una separación clara entre los dos *clusters* generados por k -means. Esta observación puede deberse a la baja varianza explicada por dichas dimensiones, ya que tenemos 19 dimensiones para explicar el 80% de la varianza. K -means se ejecutó sobre un espacio multidimensional más completo, por lo que complementaremos este análisis con métricas de validación de *clusters* como el índice de *silhouette* que veremos más adelante.

PAM

En lugar de usar centroides como el k -means, PAM usa medoides como método de definir los *clusters*. Esto hace que PAM sea más robusto y adecuado cuando los datos incluyen puntos atípicos que podrían afectar a los resultados.

El gráfico de la Figura 89 muestra la agrupación de datos obtenida con el método PAM y la distancia de euclidiana. Se observan los dos *clusters* diferenciados por color y forma, pero con una fuerte superposición entre ellos como en el *k-means*, esta representación tampoco muestra las fronteras definidas entre grupos.

CLARA

El algoritmo CLARA se utiliza cuando se trabaja con grandes volúmenes de datos. La principal diferencia es que, en lugar de trabajar con todo el conjunto de coordenadas, CLARA toma una muestra aleatoria del conjunto de coordenadas y realiza el *clustering* solo sobre esa muestra. En nuestro caso, hemos decidido usar cinco samples, una cantidad que consideramos razonable para obtener un buen equilibrio entre precisión y velocidad.

Al igual que con *k-means* y PAM, los grupos en la Figura 52 están muy mezclados y no se pueden ver las fronteras entre ellos, el gráfico es muy similar a los anteriores.



Figura 89: Proyección del PAM




Figura 90: Proyección de CLARA

Method	Silhouette Score
K-Means	0.0566
PAM	0.0371
CLARA	0.0401

Cuadro 18: Silhouette score para cada método de *clustering*

Evaluación de los resultados

Como se puede ver en la tabla 18 el mejor índice lo tiene el *k-means* que será el que elegiremos. El tener 19 dimensiones nos garantiza que se conserve la mayor parte de la información estructural original, pero también implica trabajar en un espacio de alta dimensión, lo cual puede afectar la eficacia de los métodos particionales. De hecho, el índice de *Silhouette* obtenido (0.05) indica una baja cohesión y separación entre los *clusters* generados, lo que sugiere que, la estructura de los datos no presenta grupos claramente diferenciados desde el punto de vista del *k-means*.

10.2. Profiling particional

Para realizar el profiling pertinente a nuestra situación, tenemos que aplicar el método particional. Además, debemos usar las variables y no las coordenadas como hemos hecho en el *clustering*, sabiendo que dichas variables son las ya seleccionadas por el FAMD explicado anteriormente.

Otro factor relevante para el correcto funcionamiento del proceso de profiling es la creación de una nueva variable, la cual explica a qué grupo pertenece cada variable de nuestra base de datos.

Una vez establecida nuestra nueva base de datos, utilizaremos *boxplots* y *barplots* para analizar la variables numéricas y *barplots* para las categóricas. Para no sobrecargar el texto con gráficos, remitimos al lector al archivo RMD correspondiente, donde se encuentran tanto las figuras utilizadas como los comentarios individuales iniciales de nuestro análisis. A continuación, presentamos de forma general nuestras observaciones.

Variables numéricas

Detectamos que el primer grupo de personas estudia más que la mayoría de gente pero no asiste tanto a clase y acaba obteniendo peores resultados. Por otro lado, tenemos al segundo grupo que asiste más a clase y obtiene mejores notas pese a estudiar menos. El primer grupo se podría definir como estudiantes autodidactas, prefieren estudiar por sí solos que asistir a clase. El segundo grupo sería de estudiantes presenciales, que tienden a ir a clase antes que a estudiar por su cuenta.

Variables categóricas

En general, las diferencias en frecuencia relativa entre *clusters* no son muy marcadas en la mayoría de las variables categóricas. El Cluster 1 presenta mayor participación en actividades extracurriculares, mayor percepción de influencia positiva de los pares, y estudiantes que viven a mayor distancia de la escuela, lo cual sugiere un perfil algo más activo y autónomo. El Cluster 2 se caracteriza por mayor proporción de estudiantes con influencia de compañeros neutral y mayor asistencia a escuelas privadas, aunque con diferencias poco significativas. La variable más distintiva es *Distance.From.Home*, siendo la que mayor contraste presenta entre los *clusters*. En resumen, las diferencias categóricas refuerzan solo levemente la separación entre los grupos detectados por *clustering*.

Profiling general

El primer grupo serían los **Estudiantes Trabajadores pero con Desventajas**. Esto se debe a que estudian más que el promedio, aunque tienen una asistencia ligeramente menor que el promedio, debido a posibles problemas personales (bajo involucramiento parental). También son más participativos (en actividades extracurriculares), suelen ir a escuelas públicas y viven más lejos de la escuela. Con todo esto, sus notas están por debajo del promedio.

El segundo grupo, **Estudiantes consistentes con apoyo moderado**. Estos alumnos estudian menos que el promedio y asisten a clase un poco más que el promedio. Además, son menos participativos (en actividades extracurriculares), suelen ir a escuelas privadas, viven más cerca de la escuela y tienen mayoritariamente ingresos medios. Sabiendo esto, sus notas están por encima del promedio. Este grupo, aunque estudia menos horas, tiene mejor rendimiento, posiblemente debido a una mayor asistencia, proximidad a la escuela y un entorno más estable (ingresos medios, escuelas privadas). La combinación de estos factores apunta a un perfil de estudiantes que aprovechan eficientemente su tiempo y recursos disponibles.

Visualización de las clases sobre los planos factoriales del FAMD

Como se puede ver la gráfica de la Figura 91 los puntos están proyectados sobre los dos primeros planos factoriales, que recogen la mayor parte de la variabilidad explicada por el modelo.

Cada punto representa una observación, y los colores indican el grupo asignado por el algoritmo de *clustering*: el *cluster* 1 en rojo y el *cluster* 2 en azul. Observamos superposición entre ambos grupos, tal y como se podía ver en el *clustering*, lo que sugiere que las clases no están claramente separadas en estos dos componentes principales. Aun así, se pueden identificar zonas donde predomina cada uno de los *clusters*.




Figura 91: Visualización de las clases sobre el primer plano factorial del FAMD

Comparación con el k-means de las variables originales

En esta Figura 92 se muestra la clasificación obtenida mediante el algoritmo *k-means* aplicado sobre los datos originales, proyectada sobre los dos primeros componentes factoriales del análisis FAMD. Los puntos están coloreados según los cuatro clusters resultantes.

Aunque los clusters están algo solapados, se pueden distinguir ciertas agrupaciones y patrones de densidad en diferentes regiones del gráfico, lo cual indica que el FAMD conserva parte de la estructura de agrupamiento presente en los datos originales.




Figura 92: Clasificación del *k-means* original sobre el primer plano factorial del FAMD

11. Análisis Discriminante

11.1. Variables originales e índice del clustering jerárquico

El Análisis Discriminante Lineal (LDA) busca encontrar combinaciones lineales de variables que separen lo mejor posible los grupos de una variable categórica, en este caso el grupo obtenido en el *clustering* jerárquico con variables mixtas y distancia de *Ward*.

En nuestro caso, podemos apreciar en la Figura 93 como la primera función discriminante (LD1) explica el 75 % de la varianza entre grupos y está fuertemente asociada a variables como la asistencia, la implicación parental, la actividad física y la influencia social, reflejando un eje de comportamiento y rendimiento académico. La segunda función (LD2), con un 25 % de la varianza, destaca factores socioeconómicos como el acceso a recursos, la calidad del profesorado o el nivel de ingresos familiares. Las variables *Attendance*, *Peer_InfluencePositive*, *Physical_Activity*, *Sleep_Hours* y *Access_to_Resources_Low* son especialmente relevantes para diferenciar a los grupos, como veremos más adelante.




Figura 93: Proyección de observaciones en el espacio discriminante

La separación visual de las clases en el espacio discriminante no es evidente.




Figura 94: Histogramas de las funciones discriminantes LD1 y LD2

En estos gráficos de la Figura 94 no se observa una separación clara entre las distribuciones de las distintas clases. Las curvas presentan un alto grado de solapamiento, especialmente entre las clases intermedias, lo que sugiere que ni LD1 ni LD2 logran capturar diferencias sustanciales entre los grupos definidos. Esto refuerza lo que indican los histogramas de las funciones discriminantes: aunque LD1 explica un 75 % de la varianza entre grupos, la superposición entre clases impide una buena discriminación visual. LD2, por su parte, aporta menos información y tampoco permite distinguir con claridad las categorías. Por tanto, aunque el modelo encuentra direcciones óptimas de separación, estas no resultan completamente eficaces a nivel práctico.

Al comparar los resultados obtenidos con la regla de clasificación manual aplicada tanto al conjunto de entrenamiento como al de test, observamos una precisión muy similar en ambos casos (81.7 % en entrenamiento y 82.7 % en test). Esta estabilidad confirma que el modelo no sufre de sobreajuste, ya que generaliza bien a nuevos datos. No obstante, el hecho de que la regla sea tan simple y aun así ofrezca resultados comparables refuerza la idea de que las funciones discriminantes no logran una separación clara entre clases. En definitiva, aunque el rendimiento sea consistente, la capacidad del modelo para capturar la complejidad de la estructura subyacente en los datos sigue siendo limitada.

11.2. Variables del PCA y del ACM e índice del clustering

En este caso se ha aplicado un análisis discriminante lineal utilizando como variables las componentes principales obtenidas previamente mediante PCA y ACM, con el objetivo de predecir los grupos definidos por el *clustering* jerárquico de Ward. A pesar de que las dos primeras funciones discriminantes explican conjuntamente más del 99 % de la varianza entre grupos (LD1: 72 %, LD2: 27 %), la proyección de las observaciones sobre el plano LD1–LD2 revela, una vez más, una gran superposición entre clases (Figura 95). Esto confirma que ni siquiera con variables latentes optimizadas se logra una separación clara, lo que sugiere que la estructura real de los grupos es difusa o que las variables originales no contienen suficiente información discriminativa.




Figura 95: Proyección de observaciones en el espacio discriminante

Los histogramas de las funciones discriminantes en la Figura 96 obtenidas tras aplicar LDA sobre las variables reducidas (PCA y ACM) muestran una ligera mejora respecto a los casos anteriores, especialmente en LD1, donde se observan ciertas diferencias en la forma y el desplazamiento de las distribuciones. Sin embargo, sigue existiendo un grado considerable de solapamiento entre clases, lo que limita la capacidad del modelo para realizar una clasificación precisa. Aunque las transformaciones han ayudado a simplificar la estructura de los datos, no parecen haber generado variables que separen de forma clara los grupos definidos previamente mediante *clustering*.




Figura 96: Histogramas de las funciones discriminantes LD1 y LD2

A continuación, al aplicar la regla de clasificación sobre los datos reducidos (PCA y ACM), tanto en entrenamiento como en test, se mantiene una precisión muy estable: 82.1 % y 83.1 % respectivamente. Estas cifras son muy similares a las obtenidas con los datos originales, lo que indica que la reducción dimensional no ha mejorado sustancialmente la capacidad predictiva del modelo, aunque sí ha mantenido su rendimiento sin pérdida de información relevante.

Además, las métricas por clase muestran un rendimiento algo más equilibrado que en análisis anteriores, especialmente en el conjunto de test, donde destaca una mejora clara en la sensibilidad para la clase 3 (88.6 %). En conjunto, el modelo no presenta sobreajuste, pero sigue sin capturar completamente la estructura de las clases.

11.3. Variables originales y Exam_Score discretizada

A pesar de haber aplicado dos análisis discriminantes lineales anteriores –el primero con las variables originales y el segundo con variables reducidas mediante componentes principales (PCA) y componentes múltiples (ACM)–, en ambos casos los resultados fueron poco satisfactorios desde el punto de vista predictivo. Ninguno de los modelos logró una separación clara entre los grupos generados por el *clustering* jerárquico de *Ward*, mostrando solapamientos importantes tanto en la fase de entrenamiento como en la de test.

Ante estas limitaciones, y con el objetivo de mejorar la capacidad explicativa del modelo, se ha replanteado la variable objetivo. En lugar de predecir los gru-

pos del *clustering*, se ha optado por discretizar la variable continua *Exam_Score* en tres niveles según sus cuartiles: bajo [$min, Q1$], medio ($Q1, Q3$] y alto rendimiento académico ($Q3, max$]. Esta nueva formulación permite trabajar con una variable dependiente más clara y estructurada, y aplicar un nuevo análisis LDA enfocado a predecir categorías ordenadas de desempeño estudiantil.

Después de aplicar un análisis discriminante prediciendo la variable *Exam_Score_Q* (rendimiento académico discretizado en cuartiles), observamos que la primera función discriminante (LD1) concentra el 99.85 % de la varianza explicada, mientras que LD2 apenas aporta información (0.15 %). Esto sugiere que una sola dimensión es suficiente para capturar la mayor parte de la estructura entre grupos. Esta conclusión se ve reforzada por la proyección de las observaciones en el plano LD1–LD2 de la Figura 97, donde se aprecia un patrón más definido: los grupos comienzan a ordenarse a lo largo de LD1 de forma más clara que en análisis anteriores, aunque persiste cierto solapamiento en las zonas centrales.




Figura 97: Proyección de observaciones en el espacio discriminante




Figura 98: Histogramas de las funciones discriminantes LD1 y LD2

Los histogramas (Figura 98) de las funciones discriminantes refuerzan lo observado previamente: LD1 permite distinguir visualmente los tres grupos discretizados de *Exam_Score*, con distribuciones claramente separadas a lo largo del eje. La clase

1 se agrupa en valores negativos, la clase 2 en torno al cero, y la clase 3 en valores positivos. En cambio, LD2 presenta distribuciones muy solapadas y centradas, lo que confirma su escaso aporte discriminante, ya anticipado por la proporción de varianza explicada.

A partir de los valores de LD1, se ha implementado un procedimiento para encontrar los cortes óptimos entre clases que maximicen la precisión del modelo. Mediante una búsqueda sistemática de combinaciones de puntos de corte, se ha identificado que los valores -1.0019 y 1.6185 son los que permiten una mejor separación. Estos límites definen los tres grupos ordinales de rendimiento académico con una precisión del 95.9%, notablemente superior a la obtenida en los análisis anteriores con otras variables objetivo o con los grupos del *clustering*.

En conjunto, estos resultados demuestran que discretizar la variable *Exam_Score* y aplicar LDA sobre las variables originales constituye una estrategia mucho más efectiva para clasificar a los estudiantes según su rendimiento. La estructura lineal de LD1 no solo simplifica la interpretación, sino que también proporciona un criterio robusto para establecer categorías predictivas de forma clara y eficiente.

Cuadro 19: Métricas de clasificación y matriz de confusión

	Clase 1	Clase 2	Clase 3
Sensitivity	0.9792	0.9578	0.9439
Specificity	0.9787	0.9668	0.9930
Pos Pred Value	0.9570	0.9561	0.9774
Neg Pred Value	0.9898	0.9681	0.9822
Prevalence	0.3268	0.4304	0.2428
Detection Rate	0.3200	0.4123	0.2292
Detection Prevalence	0.3343	0.4312	0.2345
Balanced Accuracy	0.9789	0.9623	0.9685

Predicción	Referencia		
	1	2	3
1	423	17	2
2	9	545	16
3	0	7	303

Los resultados finales que van de la mano con la Tabla 19 confirman la alta eficacia del modelo LDA al trabajar con la variable *Exam_Score* discretizada por cuartiles. La precisión alcanzada supera el 95% tanto en entrenamiento como en test, con valores muy elevados en sensibilidad, especificidad y valores predictivos positivos y negativos para las tres clases. La coherencia entre fases refuerza la estabilidad del modelo y muestra que no existe sobreajuste, lo que valida su capacidad de generalización.

Además, el procedimiento de clasificación basado en los cortes óptimos de LD1 ha permitido transformar la salida continua en predicciones categóricas precisas, man-

teniendo el orden y la lógica ordinal de los niveles de rendimiento académico. Este enfoque contrasta con los modelos anteriores basados en clustering, donde la asignación de grupos era menos clara y los resultados más imprecisos.

En conjunto, este análisis demuestra que cuando se dispone de una variable dependiente bien estructurada y significativa, como en este caso, LDA puede ser una herramienta muy poderosa y fiable para tareas de clasificación educativa u otros contextos similares donde se requiera segmentar grupos de forma interpretable y eficaz.

12. Análisis textual

En este apartado haremos un análisis sobre nuestra variable textual. Debido a que la base de datos anterior su variable textual había sido creada artificialmente, no cumplía con los requisitos para hacer este análisis y hemos escogido otra base de datos en la página web kaggle bajo este nombre: *100K Coursera's Course Reviews Dataset*.

La variable que analizaremos consiste en reseñas de cursos extraídas del sitio web de *Coursera*, destacar que estas reseñas están hechas en inglés.

12.1. Preprocessing

Para empezar a analizar nuestra variable, haremos la minería de texto, este proceso es el encargado de descubrir información que no existía explícitamente en ningún texto de la colección, pero que surge de relacionar el contenido de varios de ellos. Extrae información útil y patrones significativos a partir de grandes cantidades de texto no estructurado.

Para hacer text mining, primero haremos un preprocesado de los datos en el cual transformaremos los textos en algún tipo de representación estructurada o semi-estructurada que facilite su posterior análisis, en este paso hemos reducido la base de datos de 100 000 observaciones a 1000. Después, definiremos el corpus, que son documentos representativos seleccionados aleatoriamente o mediante algún método de muestreo probabilístico. Una vez hecho el corpus, el siguiente paso será convertir nuestros documentos a un formato analizable, para ello creamos una representación estructurada o semi-estructurada transformando:

1. todo a minúsculas,
2. quitando símbolos de puntuación.
3. quitando números,
4. quitando *stopwords* (palabras comunes que no aportan significado) y
5. quitando espacios en blanco redundantes.

Posteriormente, aplicamos *stemming*, que es el proceso de reducir las palabras a su raíz, como de “clasificar” a “clasific” y creamos lo que se conoce como una matriz de términos del documento (DTM). Se trata de una matriz de dimensión $m \times n$, donde m sería el número de descripciones a procesar, y n el número de términos existentes en esos documentos. Los valores de la matriz sería el número de veces que cada documento (fila) contiene el término (columna) dado.

Característica	Valor
Número de documentos	994
Número de términos	2467
Entradas no nulas	12,561
Entradas dispersas	2,439,637
Sparsity (porcentaje vacío)	99 %
Longitud máxima de término	40 caracteres
Tipo de ponderación	Frecuencia de término (tf)

Cuadro 20: Resumen de la matriz documento-término de *stemming*

Sobre estos resultados sabemos que:

- *Sparsity*: Nos dice cuantas entradas de la matriz son 0, es decir, el porcentaje de parejas documento-palabra que son 0 y nos da una idea de la similitud entre los documentos: si los documentos contienen todas las mismas palabras entonces *sparsity* será 0 y todas las casillas de la matriz tendrán algún valor diferente al 0.
- Tenemos 2467 términos y 994 palabras diferentes en nuestro Corpus.
- La palabra más larga tiene 40 letra (ya que al quitar los espacios se han juntado palabras).
- Para el *Weighting* se usa *term-frequency metric*.

Y una vez hecha la matriz, podemos generar gráficos de la Figura 99 que nos indican las palabras con más frecuencia y una nube de palabras en la que podemos ver como aparecen varias palabras con tamaños distintos según su frecuencia o importancia en el conjunto de documentos (corpus).




Figura 99: Frecuencias relativas de las palabras (izquierda) y *wordcloud* de *stemming* (derecha)

En estos se observan las palabras más frecuentes en la variable: *cours*, *great*, *good*, *learn*, *realli*, *use*, *thank*, *interest*, *lot* y *excel*.

Al ser reseñas de un curso se ven palabras claves relacionadas con el curso cómo: *cours* y *learn*. También se ven palabras de agradecimiento y cumplidos como: *great*, *good*, *thank*, *lot*, *excel* y *interest*, con lo que podemos decir que la gente está contenta y agradecida con el curso.

Volviendo atrás, antes de hacer *stemming*, hemos guardado el corpus para hacer lematización que es otro proceso de lenguaje natural (PLN) que consiste en reducir una palabra a su forma base o "lema", teniendo en cuenta su significado y contexto gramatical.

Al igual que en *stemming* también creamos la matriz de términos del documento (DTM), generamos los gráficos de frecuencia de palabras y la nube de palabras.




Figura 100: Frecuencias relativas de las palabras (izquierda) y wordcloud de lematización (derecha)

Resaltar que de la matriz DTM sus resultados son muy similares a los anteriores hechos con *stemming* (mismas palabras diferentes y sparsity similar). Y la tabla con las diez palabras más frecuentes no tiene gran variación, únicamente cambian 3 palabras, pero igualmente estas palabras siguen siendo o claves en el curso o de agradecimiento.

En conclusión, los dos procesos son muy similares, ya que solo encontramos una leve e insignificante diferencia entre los métodos.

A partir de las palabras más frecuentes en ambos enfoques (*course*, *great*, *good* y *learn*), con el objetivo de analizar qué otras palabras tienden a aparecer junto a estos términos clave dentro de los documentos, lo cual puede reflejar patrones de opinión, temas frecuentes o conceptos relacionados en los contenidos analizados. Para asegurar la relevancia de las asociaciones, se aplicó una correlación del 29 %, filtrando así las conexiones más representativas.

Cuadro 21: Palabras más frecuentes asociadas a *course*

Palabra	take	will	think	two	value	one	first	make	not
Valor	0.36	0.34	0.32	0.32	0.32	0.31	0.30	0.30	0.29

Cuadro 22: Palabras más frecuentes asociadas a *learn*

Palabra	thing	something	combination	lot	can	spreadsheet
Valor	0.34	0.33	0.30	0.30	0.29	0.29

Este análisis revela que las palabras *course* y *learn* son las que generan más asociaciones significativas y las palabras *great* y *good* no se correlacionan con otras en más de un 29 %.

Las palabras que se asocian con *learn* están relacionadas con el conocimiento o en procesos para aprender, por otro lado, las palabras que se asocian con *course* se relacionan con la participación y evaluación del curso.

12.2. Análisis sentimental

Antes de proceder a medir los sentimientos en el conjunto de datos, comenzamos examinando la estructura de las oraciones. Para ello, fragmentamos el texto en oraciones, calculamos la longitud de cada una en número de palabras, y visualizamos esta información mediante un gráfico que muestra la distribución de las longitudes junto con una curva suavizada (Figura 101). Esta exploración nos permite confirmar que la mayoría de las oraciones tienen entre 5 y 20 palabras, mientras que detectamos algunos casos excepcionales correspondientes a reseñas más extensas.




Figura 101: Longitud de oraciones

Paralelamente, verificamos que prácticamente todas las oraciones estuvieran en inglés, lo que validó el correcto filtrado por idioma. A continuación, calculamos la polaridad de cada reseña para evaluar si su contenido es positivo o negativo. Recogimos estos puntajes y representamos su distribución con un histograma que mostró un sesgo global ligeramente positivo.

Para profundizar en el vocabulario empleado, dividimos todo el texto en palabras, contabilizamos las frecuencias, eliminamos palabras muy comunes que no aportan significado y relacionamos los resultados con un diccionario de palabras positivas y negativas. De esta forma, identificamos las quince palabras con connotación positiva más frecuentes, tales como *great*, *good* y *excellent*. Estas se presentan en la Figura

102 que evidencia el énfasis de los usuarios en aspectos relacionados con la calidad y utilidad de los cursos.




Figura 102: Histograma de las palabras positivas más frecuentes

Los estudiantes tienden a dejar comentarios que varían desde neutrales hasta claramente positivos, reflejando una inclinación hacia la satisfacción, posiblemente atribuible a la buena calidad general de los cursos. La escasez de comentarios negativos podría interpretarse como un indicio del buen diseño pedagógico y de que los usuarios más comprometidos o satisfechos son quienes suelen dejar reseñas.

Posteriormente, realizamos un análisis emocional más detallado que nos permitió clasificar las reseñas según diez categorías emocionales diferentes. Sumando las ocurrencias de cada emoción, generamos los gráficos de las Figuras 103 y 104 que mostraron que las emociones “positividad”, “confianza” y “alegría” son predominantes, mientras que “enojo” y “asco” resultan prácticamente insignificantes.




Figura 103: Frecuencia de emociones




Figura 104: Distribución radial de emociones

Este análisis de frecuencia de palabras positivas refuerza estas conclusiones. Palabras como *great*, *good*, *excellent* e *interesting* son recurrentes, indicando que los estudiantes valoran muy positivamente la calidad del contenido, la claridad de las explicaciones y el interés que generan los cursos. Además, términos como *useful*, *easy* y *recommend* sugieren que los cursos son percibidos como útiles, accesibles y recomendables.

En conjunto, estos resultados reflejan una alta satisfacción general por parte de los estudiantes (Figura 105), destacando tanto la calidad académica de los cursos como la experiencia formativa positiva que ofrece la plataforma. Para representar esto visualmente, generamos una nube de palabras de emociones, donde el tamaño de cada palabra refleja su frecuencia, destacando claramente las emociones predominantes.



Figura 105: Wordcloud de emociones

Finalmente, exploramos las combinaciones de palabras que suelen aparecer juntas, limpiando pares que contienen palabras poco relevantes, y representamos esta información en un grafo (Figura 106).

En cuanto a la estructura del grafo, las combinaciones de palabras más frecuentes, como *great course* y *learn more*, se sitúan en el centro, mientras que forman pequeños grupos secundarios con términos como *video lectures* o *quiz questions*. El grupo principal contiene palabras clave como *course*, *material*, *content*, *instructor*, *useful* y *challenging*, indicando que los comentarios tienden a centrarse en la calidad del contenido, la utilidad percibida y el nivel de dificultad de los cursos.

12.3. Topic modelling

El objetivo de este análisis fue identificar los temas subyacentes más recurrentes en las reseñas mediante la técnica de *Latent Dirichlet Allocation* (LDA), y visualizar los resultados de manera clara y estructurada.

Primero de todo, debemos escoger el número de tópicos a analizar. Para ello hemos ejecutado dos métricas presentes en la Figura 107. Observamos que ambas métricas coinciden en que un número pequeño de temas (alrededor de 2 a 6) es óptimo para el modelo, siendo 2 temas el punto más favorable de acuerdo con la métrica *Deveaud2014*, y 6 temas un compromiso aceptable según *CaoJuan2009*. Elegir entre estos dependerá del equilibrio deseado entre simplicidad del modelo y riqueza temática.




Figura 107: Evaluación de dos métricas en función del número de tópicos

Para seguir con nuestro análisis hemos escogido seis tópicos. Veamos ahora los resultados.

La Figura 108 muestra una nube de palabras correspondiente al primer tópico identificado por el modelo LDA. Esta imagen se genera extrayendo las 50 palabras más representativas del tema, ordenadas según su probabilidad dentro del tópico. Términos como *question*, *student*, *course*, *video*, *review*, *help*, *understand* y *example* destacan en tamaño, indicando su importancia relativa dentro del tema. El conjunto léxico sugiere que este tópico está centrado en el proceso de aprendizaje y resolución de dudas por parte del alumnado, probablemente vinculado con la calidad de los vídeos, la claridad de los contenidos y la utilidad de las revisiones. Además, la inclusión de términos como *quiz*, *content* y *instructor* refuerza la idea de que el tópico captura aspectos pedagógicos clave de los cursos en línea.

En la Figura 109 se presenta una visualización de las proporciones temáticas de esos tres documentos seleccionados. Cada gráfico de barras apiladas muestra la distribución de los seis tópicos identificados en el corpus. El documento 2 (gráfico central) destaca por tener una concentración muy elevada en el tópico vinculado a la introducción de herramientas, como indica la predominancia del término *ableton* en el título del tema. En cambio, el documento 1 presenta una mezcla en la que el tópico centrado en estudiantes, dudas y revisiones ocupa la mayor parte, aunque coexiste con otros temas secundarios. Finalmente, el documento 3 combina tópicos relacionados con habilidades de escritura, finanzas y agradecimientos hacia el curso, lo que sugiere una mayor heterogeneidad temática. Esta comparación permite apreciar cómo el modelo LDA es capaz de capturar la complejidad de las reseñas y representarla de manera visualmente interpretable.

Este enfoque resulta especialmente útil en el contexto de nuestra base de datos ya que permite descomponer una gran cantidad de textos no estructurados en componentes semánticos interpretables. Esto facilita detectar qué elementos valoran más los estudiantes –por ejemplo, la claridad del contenido, la efectividad del material audiovisual o el acompañamiento docente– y cómo se distribuyen estas percepciones entre diferentes cursos. Estas conclusiones pueden ser de gran utilidad para instituciones educativas que buscan mejorar su oferta formativa en línea basándose en las valoraciones expresadas directamente por los usuarios.

13. Análisis comparativo

13.1. ACP

El ACP revela dimensiones latentes claras en las variables continuas del estudio. La primera dimensión resume la performance académica general de los estudiantes, la segunda refleja un *trade-off* entre métodos de aprendizaje (autoestudio vs. tutorías) y la tercera atañe a hábitos de salud/actividad. Gracias a la alta varianza explicada por estos componentes, el ACP logra una representación parsimoniosa de los datos numéricos sin una pérdida sustancial de información. No obstante, cabe señalar que la interpretación de los componentes requirió complementarse con gráficos para extraer conclusiones significativas, dado que las magnitudes numéricas por sí solas ofrecen información limitada sobre la naturaleza de cada factor. Además, una limitación intrínseca del ACP es que considera únicamente variables cuantitativas continuas; por ende, aspectos capturados en variables categóricas (por ejemplo, entorno familiar o tipo de centro educativo) no se reflejan en estos componentes y deberán explorarse con otros métodos.

13.2. ACM

El ACM, en este caso, presenta la limitación de una baja capacidad de reducción dimensional útil. Al no haber dimensiones claramente predominantes, no fue posible descartar variables cualitativas sin perder información importante — de hecho, se observó que no se podía reducir el conjunto de variables categóricas a usar en el análisis mixto subsecuente, dado que ninguna parecía totalmente prescindible según el *screeplot*. Esta falta de un “corte” natural en la distribución de la varianza posiblemente se deba a la naturaleza artificial del conjunto de datos, donde las relaciones entre categorías no siguen patrones fuertes como se esperaría en datos reales. En síntesis, el ACM reveló algunos patrones latentes de asociación entre categorías (principalmente alineados con factores socioeconómicos y de recursos educativos), pero cada uno de estos patrones aporta una fracción muy pequeña de la inercia total. Consecuentemente, el espacio categórico requiere muchas dimensiones para describir variaciones significativas, dificultando la interpretación global y la síntesis de la información cualitativa en unos pocos ejes comprensibles.

13.3. FAMD

En conclusión del FAMD, se evidencia que, aunque esta técnica es adecuada en principio para datos heterogéneos, su efectividad se vio muy limitada por las características del dataset analizado. La escasa varianza explicada por los primeros componentes sugiere patrones débiles o altamente multidimensionales que no se pueden resumir en pocas dimensiones. Es plausible que la naturaleza artificial de los datos sea un factor crítico detrás de estos resultados: al no provenir de procesos reales, las relaciones entre variables podrían carecer de la estructura coherente que los métodos factoriales lineales son capaces de captar. Además, cualquier posible relación no lineal o compleja entre las variables mixtas no será detectada por FAMD.

debido a su carácter lineal. En definitiva, el FAMD no logró proporcionar una reducción dimensional eficaz en este caso, y sus ejes latentes deben interpretarse con mucha cautela. Esto contrasta claramente con el ACP de las variables numéricas, donde los primeros componentes sí representaban factores latentes bien definidos (rendimiento, método de estudio, etc.). La experiencia sugiere que, para este conjunto de datos, los métodos factoriales estándar tienen dificultad para condensar la información mixta, por lo que se recurre a complementar el análisis con técnicas de clustering para buscar agrupaciones de individuos más interpretables.

Los clusters jerárquicos ofrecen una visión integrada: combinan criterios de rendimiento y de entorno. Curiosamente, los perfiles identificados aquí conectan elementos que en los métodos anteriores aparecían por separado. Por ejemplo, el Cluster C destaca a los alumnos tenaces de bajos recursos – una temática insinuada en el ACM/FAMD (baja renta y alta motivación/asistencia) – mientras que el Cluster B recoge a los alumnos sobresalientes con poca intervención familiar – alineado con la idea del Grupo 2 de *k-means* pero incorporando además la variable de calidad de centro. El Cluster A, por su parte, evidencia que tener apoyo familiar no garantiza el éxito si concurren otros factores negativos (posible reflexión sobre la calidad docente o características personales).

13.4. Comparación de métodos

En conjunto, la aplicación de varios métodos de clustering demuestra que la forma de agrupar a los individuos depende fuertemente del enfoque del algoritmo y de las variables consideradas. El *kmeans* reveló la estratificación por rendimiento cuantitativo, el PAM mostró segmentaciones por contexto cualitativo, y el análisis jerárquico sugiere perfiles combinados más holísticos. Cabe mencionar que algunos factores inicialmente considerados importantes no resultaron ser divisores clave en ningún agrupamiento: por ejemplo, variables como *Teacher_Quality* (calidad del profesor) o *Motivation_Level* no diferenciaron claramente los clusters. En los gráficos de frecuencia por cluster, se observó que los tres grupos principales tenían proporciones similares de estudiantes con alta, media o baja calidad docente y niveles de motivación altos o bajos, indicando que estos factores no fueron determinantes en la segmentación. Su efecto pudo haber quedado diluido por variables más fuertes (como el tipo de centro o los recursos disponibles, en el caso de la calidad docente) o porque la motivación elevada era poco común en general, manifestándose más bien niveles medios-bajos en todos los perfiles. Este hallazgo refuerza la idea de que no todas las variables que a priori se esperaban relevantes terminan siéndolo en la separación efectiva de grupos, subrayando la necesidad de un análisis cuidadoso para identificar qué factores realmente distinguen a los individuos en los datos.

A partir de la aplicación combinada de técnicas multivariantes (ACP, ACM, FAMD) y métodos de clustering, se logra una comprensión comparativa de los patrones latentes y agrupaciones de individuos en el conjunto de datos estudiado.

Los resultados indican que las variables de rendimiento académico y dedicación de estudio son las que mejor explican las agrupaciones de estudiantes en este dataset. En cambio, las variables socio-familiares y contextuales tuvieron una influencia

más tenue y compleja. No obstante, esas agrupaciones contextuales presentaron rendimientos académicos similares entre sí, lo que sugiere que factores como el apoyo familiar, el ingreso o el entorno escolar, si bien distinguen tipologías de estudiantes, no se tradujeron en diferencias marcadas de resultados académicos dentro de este conjunto artificial. En síntesis, las variables académicas cuantitativas explicaron mejor la estructura de grupos cuando el criterio de agrupación enfatiza diferencias en desempeño, mientras que los factores cualitativos requieren un enfoque específico para manifestarse y, aun así, su efecto sobre el rendimiento puede quedar eclipsado por otros elementos.

Las dimensiones latentes derivadas del ACP son las más representativas y claras en términos de varianza explicada y significado. El Componente 1 del PCA, asociado al rendimiento académico global, sobresale como la dimensión latente individual más importante identificada en el estudio, concentrando una proporción significativa de información (25 % de la varianza) y correlacionándose con variables cruciales como la nota de examen y la asistencia. Por el contrario, ninguna dimensión individual del ACM o del FAMD alcanzó un nivel comparable de relevancia. No emergió una dimensión latente dominante para los datos mixtos; a diferencia del ACP, donde la Dim1 por sí sola ya era informativamente valiosa, en el contexto cualitativo y mixto las “mejores” dimensiones latentes siguen siendo de baja representatividad. En términos prácticos, los factores continuos de rendimiento y estudio (ACP) resultaron ser las dimensiones más sólidas y útiles para entender la variabilidad principal entre estudiantes, mientras que los factores latentes cualitativos fueron difusos y de alcance limitado, requiriendo muchas dimensiones para describir modestamente las diferencias. Este contraste pone de manifiesto que los aspectos académicos cuantitativos constituyen los ejes latentes más estructurantes en el dataset analizado, en tanto que las dimensiones latentes asociadas a contexto socio-familiar son más sutiles y fragmentadas.

Si bien el ACP mostró ser muy efectivo en este caso para resumir las variables numéricas, su limitación principal es que solo incorpora relaciones lineales entre variables cuantitativas. El análisis de correspondencias múltiples acusó la limitación de la baja varianza explicada por eje, lo cual dificulta la reducción dimensional. En este dataset, no fue posible identificar un subconjunto reducido de dimensiones o de variables cualitativas que capturase la mayor parte de la información. Otra limitación práctica observada es que muchas categorías resultaron estar próximas al centro de los ejes factoriales, puede verse afectado por la presencia de muchas categorías raras o desequilibradas. La principal limitación evidenciada por el FAMD fue su escasa eficacia en la reducción de dimensionalidad para datos mixtos complejos. Mostró baja calidad de representación en sus primeros ejes

14. Conclusiones generales

Este trabajo comparativo evidencia que las técnicas multivariantes ofrecen perspectivas complementarias sobre un mismo conjunto de datos educativos. El ACP destacó las principales dimensiones latentes cuantitativas, mostrando que el rendimiento académico y la dedicación explican gran parte de la variabilidad entre estudiantes. El ACM, aunque de menor poder reductivo, insinuó ciertas asociaciones cualitativas (socioeconómicas y de recursos) presentes en el trasfondo. El FAMD trató de unificar ambos mundos, pero sus resultados subrayan las dificultades de resumir datos mixtos cuando no hay factores predominantes claros, especialmente en datos simulados.

Por su parte, el *clustering* corroboró que los estudiantes pueden agruparse de formas distintas según se consideren principalmente criterios de rendimiento o de contexto: los factores académicos numéricos forman agrupaciones claramente diferenciadas en desempeño, mientras que los factores latentes socio-familiares generan agrupaciones con diferencias menos dramáticas en resultados pero relevantes para comprender las condiciones de cada perfil. Cada método tuvo sus limitaciones, pero en conjunto proporcionan una imagen más rica: los factores académicos resultaron ser los ejes estructurantes más fuertes, modulados por distintos grados de apoyo y contexto que, si bien no cambian drásticamente el rendimiento en este dataset, sí ofrecen claves para intervenciones educativas.

En un contexto aplicado, esto sugiere que para explicar y predecir el desempeño de alumnos sería más eficaz centrar la atención en variables como asistencia, historial académico y hábitos de estudio, sin dejar de considerar –mediante análisis específicos– cómo el entorno familiar y escolar matiza estos resultados. Las dimensiones latentes identificadas y las agrupaciones encontradas proporcionan así una base objetiva para discutir políticas educativas: refuerzan la centralidad de la participación y el esfuerzo del estudiante en su éxito académico, a la vez que invitan a no descuidar las desigualdades de contexto que, aunque no siempre se traduzcan en brechas instantáneas de rendimiento, forman parte integral del perfil de cada estudiante y de sus oportunidades a largo plazo.

En definitiva, el análisis realizado sobre el conjunto de datos *Student Performance Factors* de Kaggle permite identificar que los factores más influyentes en el rendimiento académico de los estudiantes son, principalmente, aquellos relacionados con su dedicación personal: la asistencia a clase, el esfuerzo individual y los hábitos de estudio destacan como variables clave. Aunque el contexto socio-familiar (como el nivel de ingresos o el tipo de centro) también desempeña un papel relevante, su influencia es más difusa y difícil de captar con precisión mediante técnicas lineales estándar. Estos hallazgos refuerzan la importancia de centrar las políticas educativas en potenciar la implicación activa del alumnado, sin descuidar la necesidad de compensar desigualdades estructurales que puedan limitar sus oportunidades. Así, el enfoque multivariante adoptado no solo contribuye a entender mejor qué factores inciden en el rendimiento, sino que también aporta una base empírica para el desarrollo de sistemas educativos más eficaces y equitativos.

15. Plan de trabajo Real

En general, el desarrollo del proyecto ha seguido fielmente la planificación original y no se han presentado dificultades destacables. El único cambio relevante ha sido en la distribución de los apartados de Análisis de Correspondencias Múltiples (ACM) y Clustering FAMD, que fueron intercambiados entre los grupos de Pau, Diego y Lília; y Ferran, Max y Salomón, en función de los conocimientos previos de cada grupo. Este ajuste permitió que cada grupo trabajara en las secciones que dominaba mejor, lo que facilitó tanto el trabajo individual como la integración final. Gracias a esta reorganización, la preparación de la presentación también resultó más sencilla, ya que cada miembro pudo centrarse en explicar la parte que había trabajado. En conjunto, la colaboración dentro del grupo ha sido fluida y eficiente.

Participant [†]	Diego	Ferran	Gonzalo	Jovan	Juan_Ignacio	Lília	Max	Pau	Salomón
Editar pdf LATEX				X					
Editar código HTML			x	X					
Preparar diapositivas PPT	x	X	x	x	x	x	x	x	x
Practicar presentaciones	x	x	x	x	x	x	x	x	x
Entrega D2 (3)	x		x	X				x	
Estructura de datos/Metadata (4)		X					x		x
Descriptiva univariante (5.1)			X		x				
Descriptiva bivariante (6)	x					x		X	
Preprocessing (5.2)		X		x			x	x	x
Clustering particional (7.1)						x		X	
Clustering jerárquico (7.2)			x	X	x				
Profiling (8)	x		x	X	x				
ACP (9)			x	X	x				
ACM (10)	x					x		X	
FAMD (11)	x					x		X	
Clustering FAMD (12)		X					x		x
Análisis discriminante (13)			x	X	x				
Análisis Textual (14)		X		x			x		x
Análisis Comparativo, Conclusiones Generales (15,16)			x	X					
Plan de Trabajo y repartición real (17)				X					

[†] X: Líder de la tarea; x: Integrante de la tarea; Número: Apartado de la tarea

Figura 110: Plan de trabajo real